Линейная классификация

Лекция 3

План лекции

- Линейные модели классификации
- Метрики качества классификации
- Логистическая регрессия
- Обучение логистической регрессии
- Метод опорных векторов
- Многоклассовая классификация

Линейные модели классификации

- Обозначим:
 - $\mathbb{X} = \mathbb{R}^d$ пространство объектов
 - $Y = \{-1, +1\}$ множество допустимых ответов
 - $X = \{(\vec{x}_i, y_i)\}_{i=1}^l$ обучающая выборка
- Линейная модель классификации:

$$a(\vec{x}) = sign(\langle \vec{w}, \vec{x} \rangle + w_0) = sign\left(\sum_{j=1}^d w_j x_j + w_0\right),$$

где $\overrightarrow{w} \in \mathbb{R}^d$ – вектор весов, $w_0 \in \mathbb{R}$ – сдвиг, sign – функция знака:


$$sign u = \begin{cases} +1, u > 0 \\ 0, u = 0 \\ -1, u < 0 \end{cases}$$

• Если $x_0 = 1$, тогда $a(\vec{x}) = sign(\vec{w}, \vec{x})$

- Линейный классификатор соответствует гиперплоскости с вектором нормали \overrightarrow{w}
- Величина скалярного произведения $\langle \vec{w}, \vec{x} \rangle$ пропорциональна расстоянию от гиперплоскости до точки \vec{x} , а его знак показывает, с какой стороны от гиперплоскости находится данная точка
- Расстояние от точки до гиперплоскости:

$$\frac{|\langle \vec{w}, \vec{x} \rangle|}{\|\vec{w}\|}$$

• Линейный классификатор разделяет пространство на две части с помощью гиперплоскости, и при этом одно полупространство относится к положительному классу, а другое – к отрицательному



• Уравнение прямой по двум точкам:


$$(x_{1a}, x_{2a}) = (0, 3), (x_{1b}, x_{2b}) = (6, 0)$$


$$(x_{2a} - x_{2b})x_1 + (x_{1b} - x_{1a})x_2 + (x_{1a}x_{2b} - x_{1b}x_{2a}) = 0$$


$$3x_1 + 6x_2 - 18 = 0$$


$$x_1 + 2x_2 - 6 = 0$$


$$\vec{w} = (1, 2), ||\vec{w}|| = \sqrt{1^2 + 2^2} = \sqrt{5} \approx 2.236$$











Функционалы качества/ошибки

• Доля правильных ответов или *правильность* (accuracy):

$$Q(a,X) = \frac{1}{l} \sum_{i=1}^{l} [a(\vec{x}_i) = y_i],$$

где [⋅] – нотация (скобка) Айверсона:

$$[P] = egin{cases} 1, {
m если} \, P - {
m истинно} \ 0, {
m если} \, P - {
m ложно} \end{cases}$$

• Доля неправильных ответов:

$$Q(a,X) = \frac{1}{l} \sum_{i=1}^{l} [a(\vec{x}_i) \neq y_i] = \frac{1}{l} \sum_{i=1}^{l} [sign\langle \vec{w}, \vec{x}_i \rangle \neq y_i] \rightarrow \min_{\vec{w}}$$

– дискретная функция

Функционал ошибки

• Модифицированный вариант:

$$Q(a,X) = \frac{1}{l} \sum_{i=1}^{l} [y_i \langle \overrightarrow{w}, \overrightarrow{x}_i \rangle < 0] \to \min_{\overrightarrow{w}}$$

- Величина $M=y_i\langle \overrightarrow{w},\overrightarrow{x}_i\rangle$ называется отступом (margin)
- Знак отступа говорит о корректности ответа классификатора:
 - ullet положительный отступ ightarrow правильный ответ
 - отрицательный отступ ightarrow неправильный ответ
- Абсолютная величина отступа характеризует степень уверенности классификатора в своём ответе

Функция потерь

• Функция потерь (пороговая):

$$L(M) = [M < 0]$$


• Если оценить эту функцию сверху:

$$L(M) \leq \tilde{L}(M)$$
,

то можно получить верхнюю оценку для функционала ошибки:

$$Q(a,X) \le \frac{1}{l} \sum_{i=1}^{l} \tilde{L}(y_i \langle \vec{w}, \vec{x}_i \rangle) \to \min_{\vec{w}}$$

Функция потерь





Функция потерь

- 1. $\tilde{L}(M) = log(1 + e^{-M})$ логистическая функция потерь (L)
- 2. $\tilde{L}(M) = (1-M)_+ = max(0,1-M)$ кусочно-линейная функция потерь (hinge loss) (метод опорных векторов) (V)
- 3. $\tilde{L}(M) = (-M)_+ = max(0, -M)$ кусочно-линейная функция потерь (персептрон Розенблатта) (Н)
- 4. $\tilde{L}(M)=e^{-M}$ экспоненциальная функция потерь (AdaBoost) (E)
- 5. $\tilde{L}(M) = \frac{2}{(1+e^M)}$ сигмоидная функция потерь (S)
- 6. $\tilde{L}(M) = (1 M)^2$ квадратичная функция потерь (Q)

Матрица ошибок (confusion matrix):

		Оценка классификатора	
		a(x) = +1 (Positive)	a(x) = -1 (Negative)
Истинные ответы	y = +1	TP (True Positive)	FN (False Negative)
	y = -1	FP (False Positive)	TN (True Negative)





• Accuracy (Правильность):

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

• Precision (Точность):

$$P = \frac{TP}{TP + FP}$$

• Recall (Полнота):

$$R = \frac{TP}{TP + FN}$$

• F1-measure (F1-score, F1-мера):

$$F1 = \frac{2PR}{P+R}$$

• Микроусреднение (micro-averaging):

$$P^{micro} = \frac{\sum_{i=1}^{n} TP_i}{\sum_{i=1}^{n} (TP_i + FP_i)}, \qquad R^{micro} = \frac{\sum_{i=1}^{n} TP_i}{\sum_{i=1}^{n} (TP_i + FN_i)},$$

$$F_1^{micro} = \frac{2P^{micro}R^{micro}}{P^{micro} + R^{micro}}$$

Макроусреднение (macro-averaging):

$$P^{macro} = \frac{\sum_{i=1}^{n} P_i}{n}, \qquad R^{macro} = \frac{\sum_{i=1}^{n} R_i}{n},$$

$$F_1^{macro} = \frac{\sum_{i=1}^{n} F_{1i}}{n}$$