

# Алгоритм обратного распространения ошибки


Лекция 2

# Граф вычислений


- Нейронная сеть = сложная функция = композиция простых функций
- Градиентный спуск = дифференцирование сложной функции
- *Граф вычислений* – направленный граф, узлами которого являются функции (простые), а ребра связывают функции со своими аргументами
- Современные библиотеки для построения нейронных сетей включают модули автоматического дифференцирования

# Граф вычислений


$$f(x, y) = x^2 + xy + (x + y)^2$$



(a)



(б)



(B)

# Производная композиции функций

- Производная композиции функций (сложной функции):

$$\left(f(g(x))\right)' = f'(g(x))g'(x)$$

– цепное правило (chain rule)

$$\frac{df}{dx} = \frac{df}{dg} \frac{dg}{dx},$$

где  $f, g$  – скалярные функции,  $x$  – скалярная переменная

# Производная композиции функций

- Если  $\vec{x} = (x_1, \dots, x_d)$ ,  $f$  и  $g$  – скалярные функции, тогда градиент композиции функций:

$$\nabla_{\vec{x}} f(g(\vec{x})) = \begin{pmatrix} \frac{\partial f(g)}{\partial x_1} \\ \vdots \\ \frac{\partial f(g)}{\partial x_d} \end{pmatrix} = \begin{pmatrix} \frac{\partial f}{\partial g} \frac{\partial g}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial g} \frac{\partial g}{\partial x_d} \end{pmatrix} = \frac{\partial f}{\partial g} \nabla_{\vec{x}} g$$

# Производная композиции функций

- Если  $x$  – скалярная переменная,

$\vec{g} = (g_1, \dots, g_m)$  – вектор-функция,

$f = f(g_1(x), \dots, g_m(x))$  – скалярная функция,

тогда производная:

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial g_1} \frac{\partial g_1}{\partial x} + \dots + \frac{\partial f}{\partial g_m} \frac{\partial g_m}{\partial x} = \sum_{i=1}^m \frac{\partial f}{\partial g_i} \frac{\partial g_i}{\partial x}$$

# Производная композиции функций

- Если  $\vec{x} = (x_1, \dots, x_d)$  – вектор,  
 $\vec{g} = (g_1, \dots, g_m)$  – вектор-функция,  
 $f = f(g_1(\vec{x}), \dots, g_m(\vec{x}))$  – скалярная функция,  
тогда градиент композиции функций:

$$\nabla_{\vec{x}} f = \frac{\partial f}{\partial g_1} \nabla_{\vec{x}} g_1 + \dots + \frac{\partial f}{\partial g_m} \nabla_{\vec{x}} g_m = \sum_{i=1}^m \frac{\partial f}{\partial g_i} \nabla_{\vec{x}} g_i$$

$$\nabla_{\vec{x}} f = \nabla_{\vec{x}} \vec{g} \nabla_{\vec{g}} f = \underbrace{\begin{pmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_m}{\partial x_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_1}{\partial x_d} & \dots & \frac{\partial g_m}{\partial x_d} \end{pmatrix}}_{\text{матрица Якоби}} \begin{pmatrix} \frac{\partial f}{\partial g_1} \\ \vdots \\ \frac{\partial f}{\partial g_m} \end{pmatrix}$$

матрица Якоби

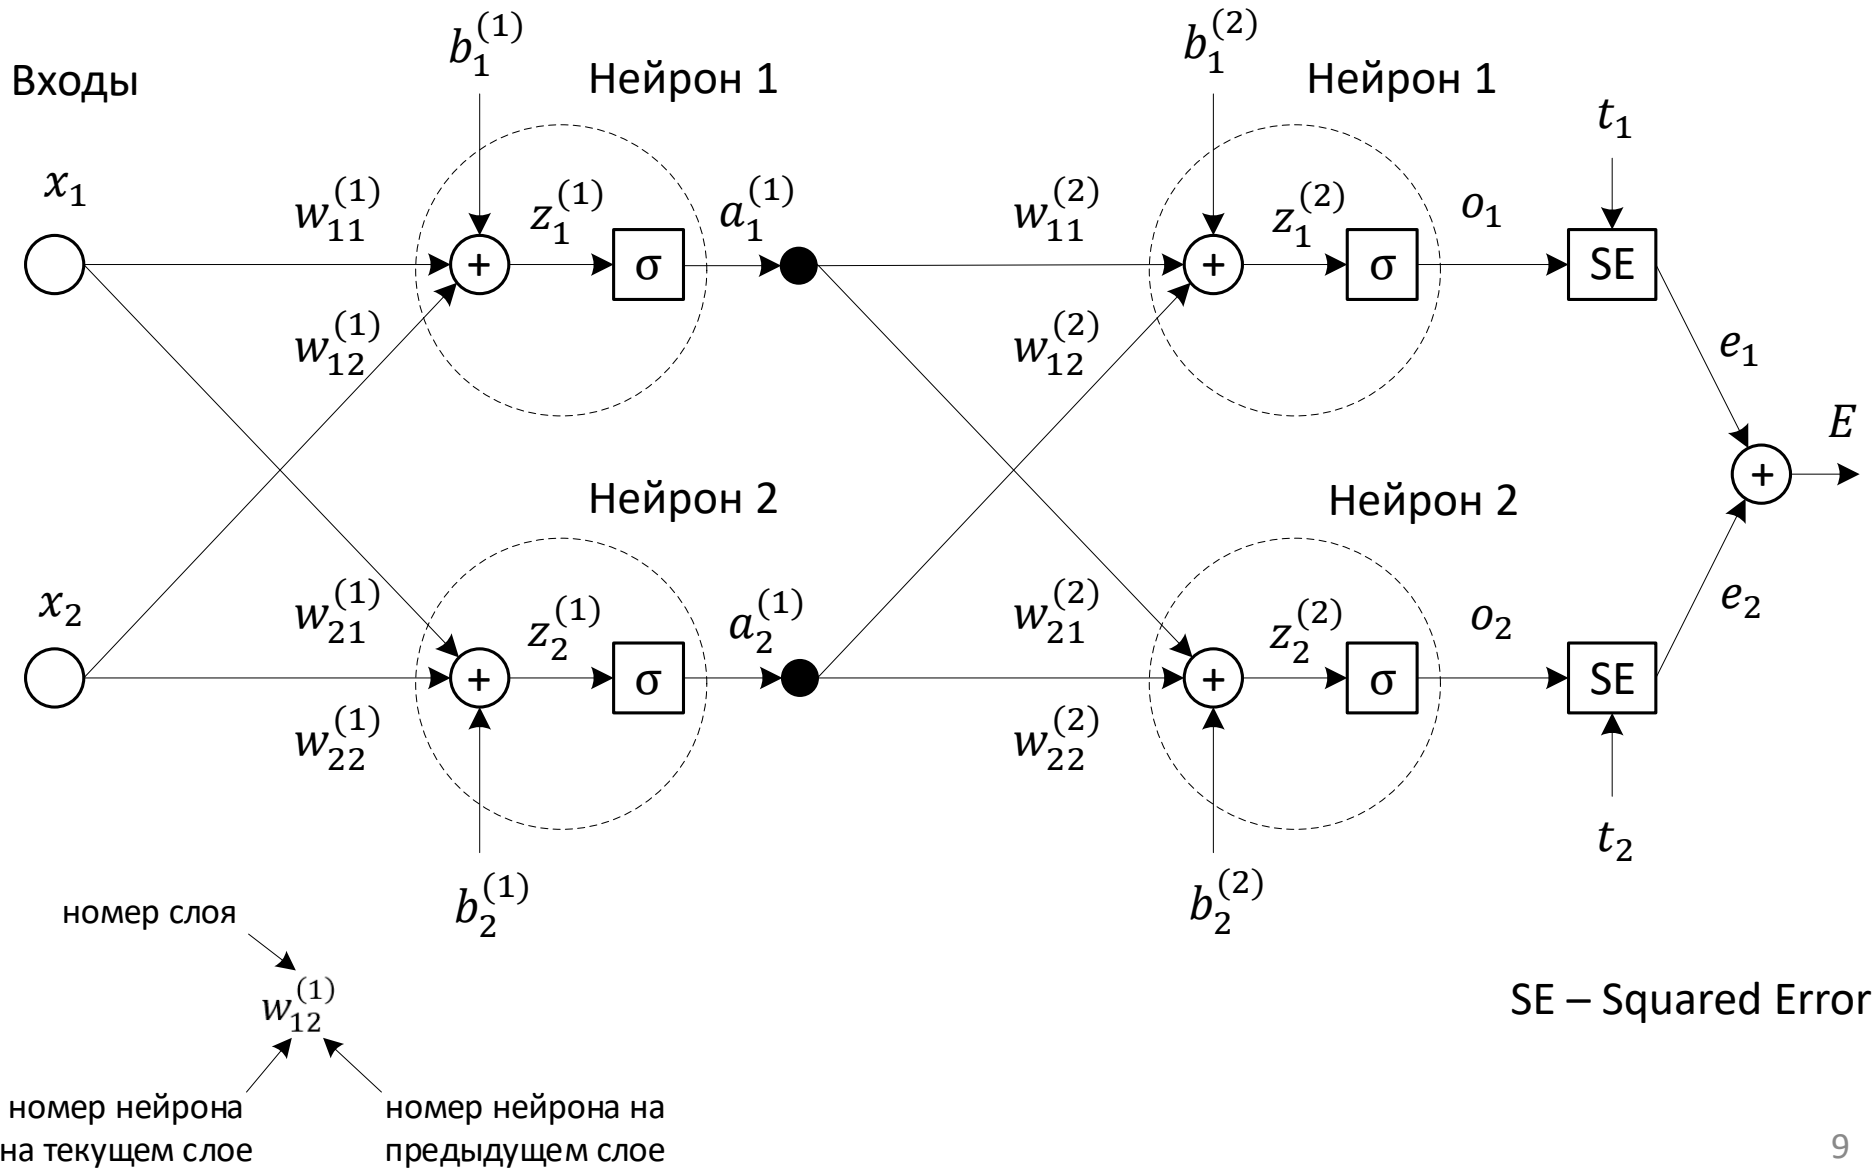
# Алгоритм обратного распространения ошибки

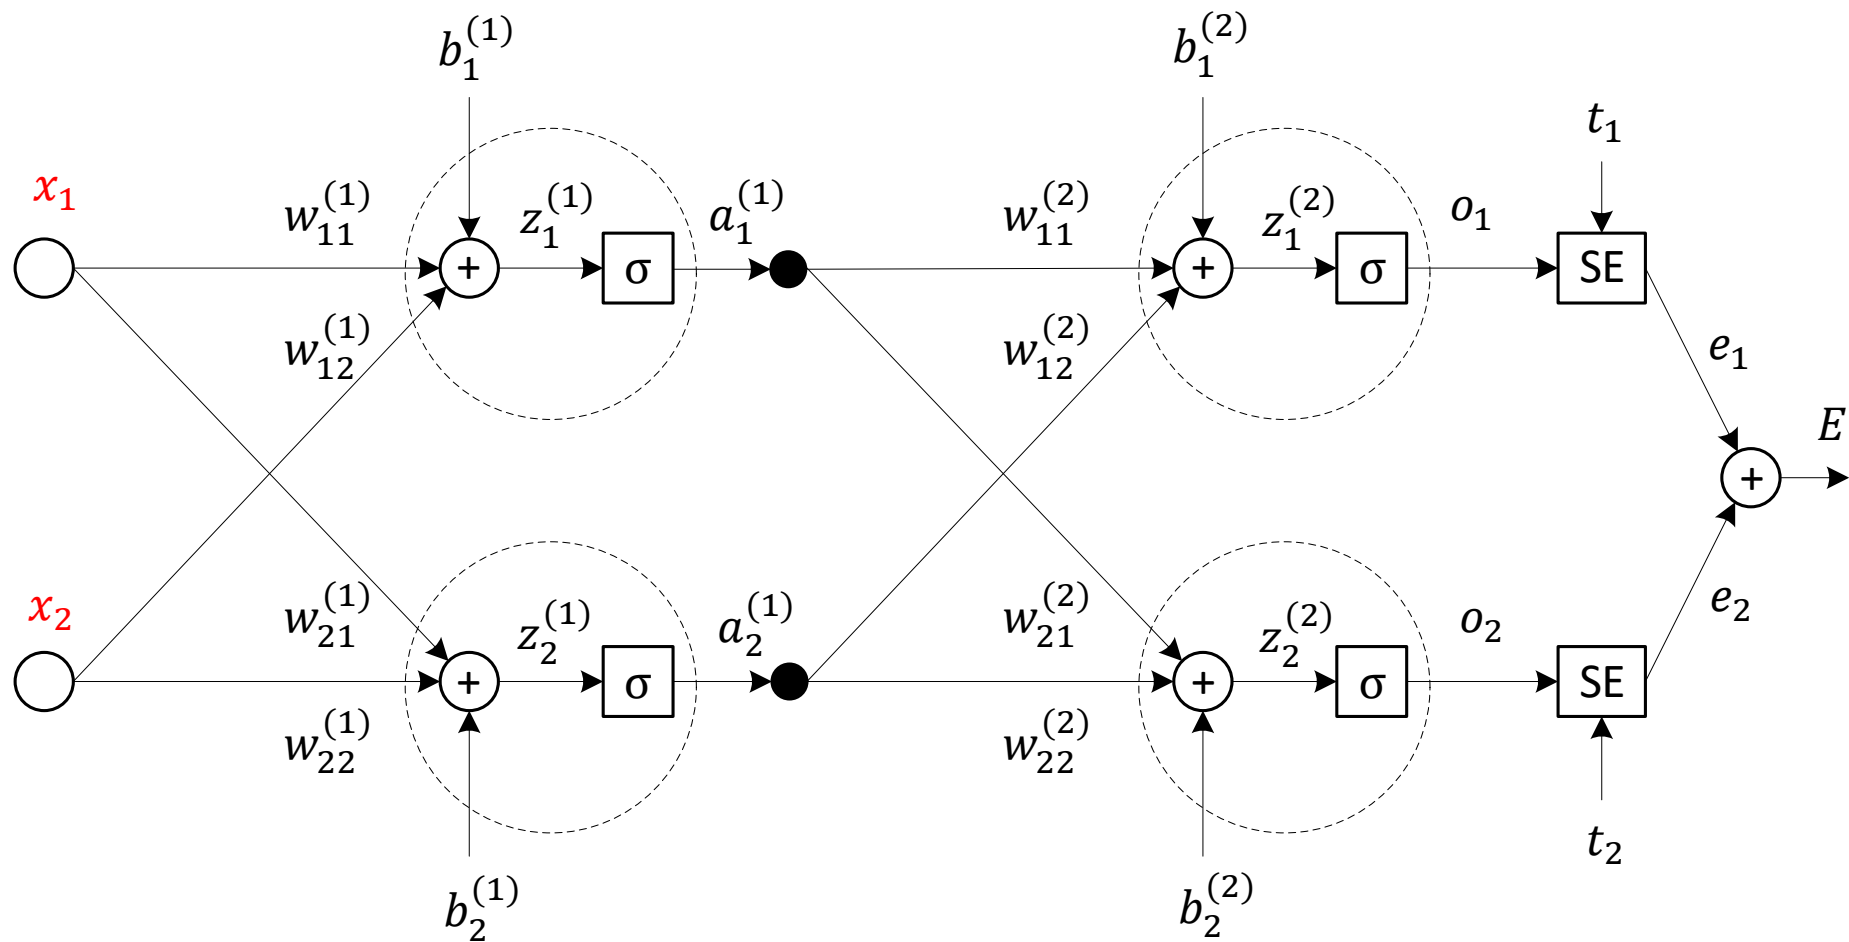
- Алгоритм обратного распространения ошибки (**backpropagation**) – метод вычисления градиента функции потерь в нейронных сетях на основе цепного правила
  - Часто подразумевается и изменение весов, то есть градиентный спуск
- Создание:
  - Linnainmaa Seppo – The representation of the cumulative rounding error of an algorithm as a Taylor expansion of the local rounding errors (Masters) (in Finnish). University of Helsinki. 1970
  - Rumelhart David, Hinton Geoffrey, Williams Ronald. Learning representations by back-propagating errors // Nature. 1986. Vol. 323

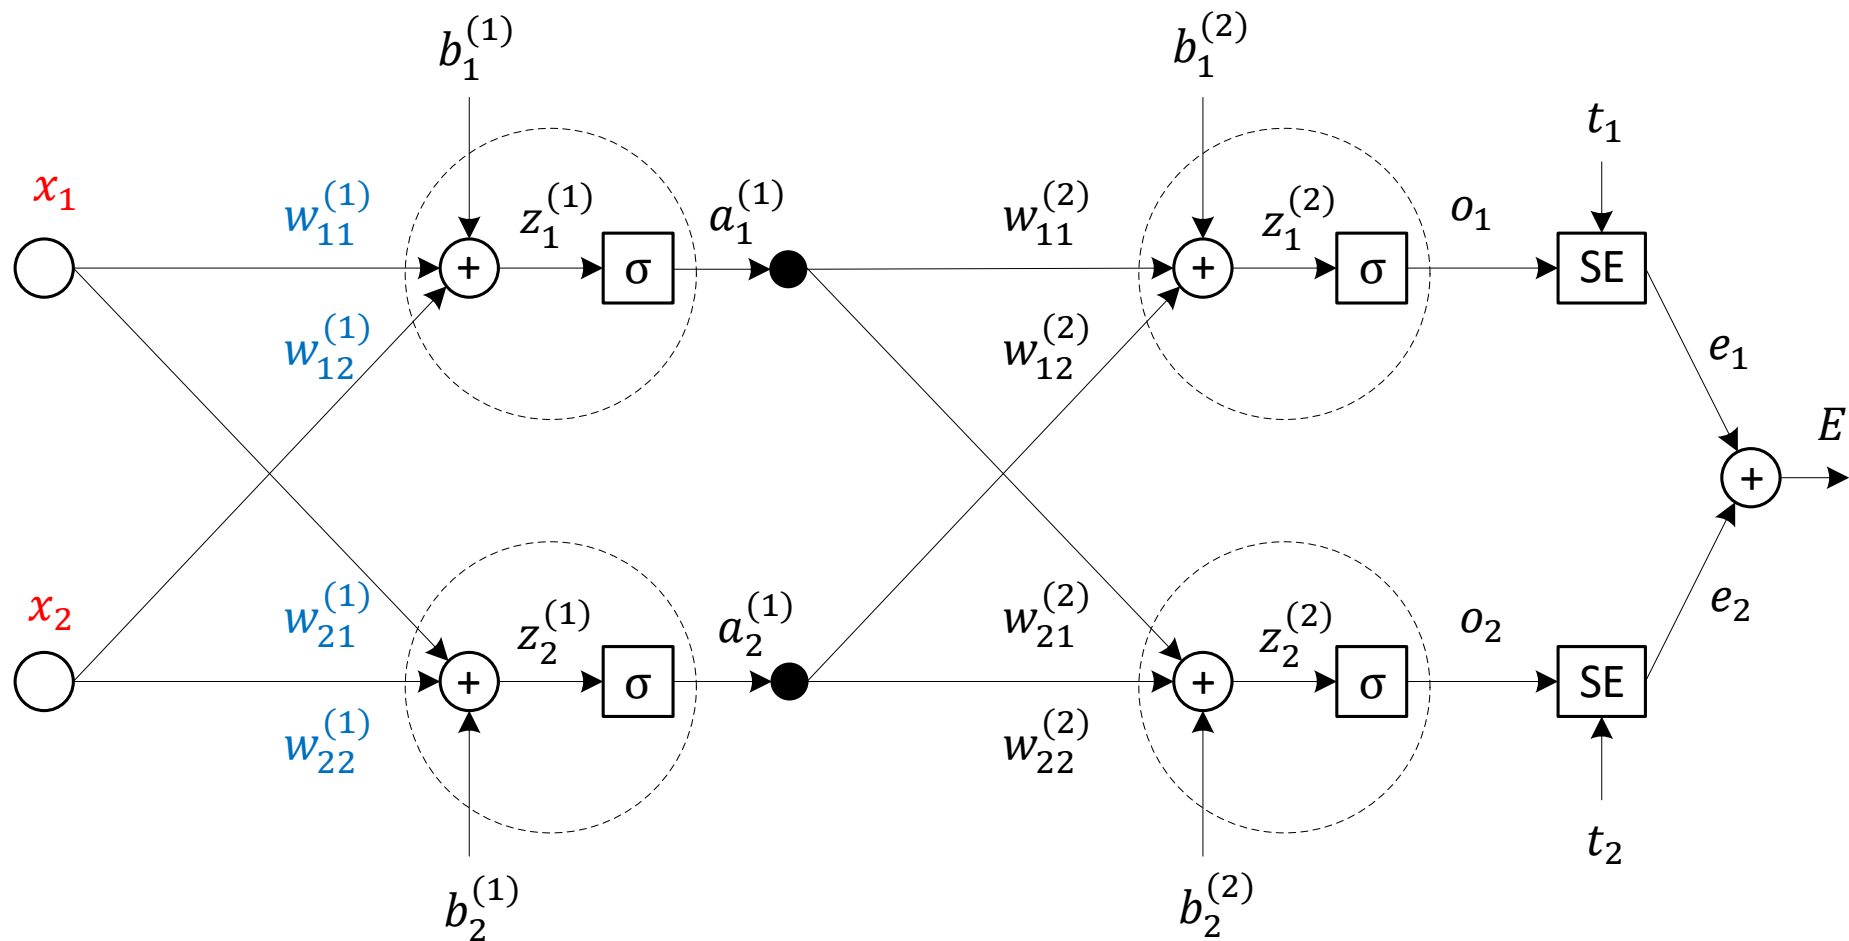


## Первый (скрытый) слой

## Второй (выходной) слой







$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

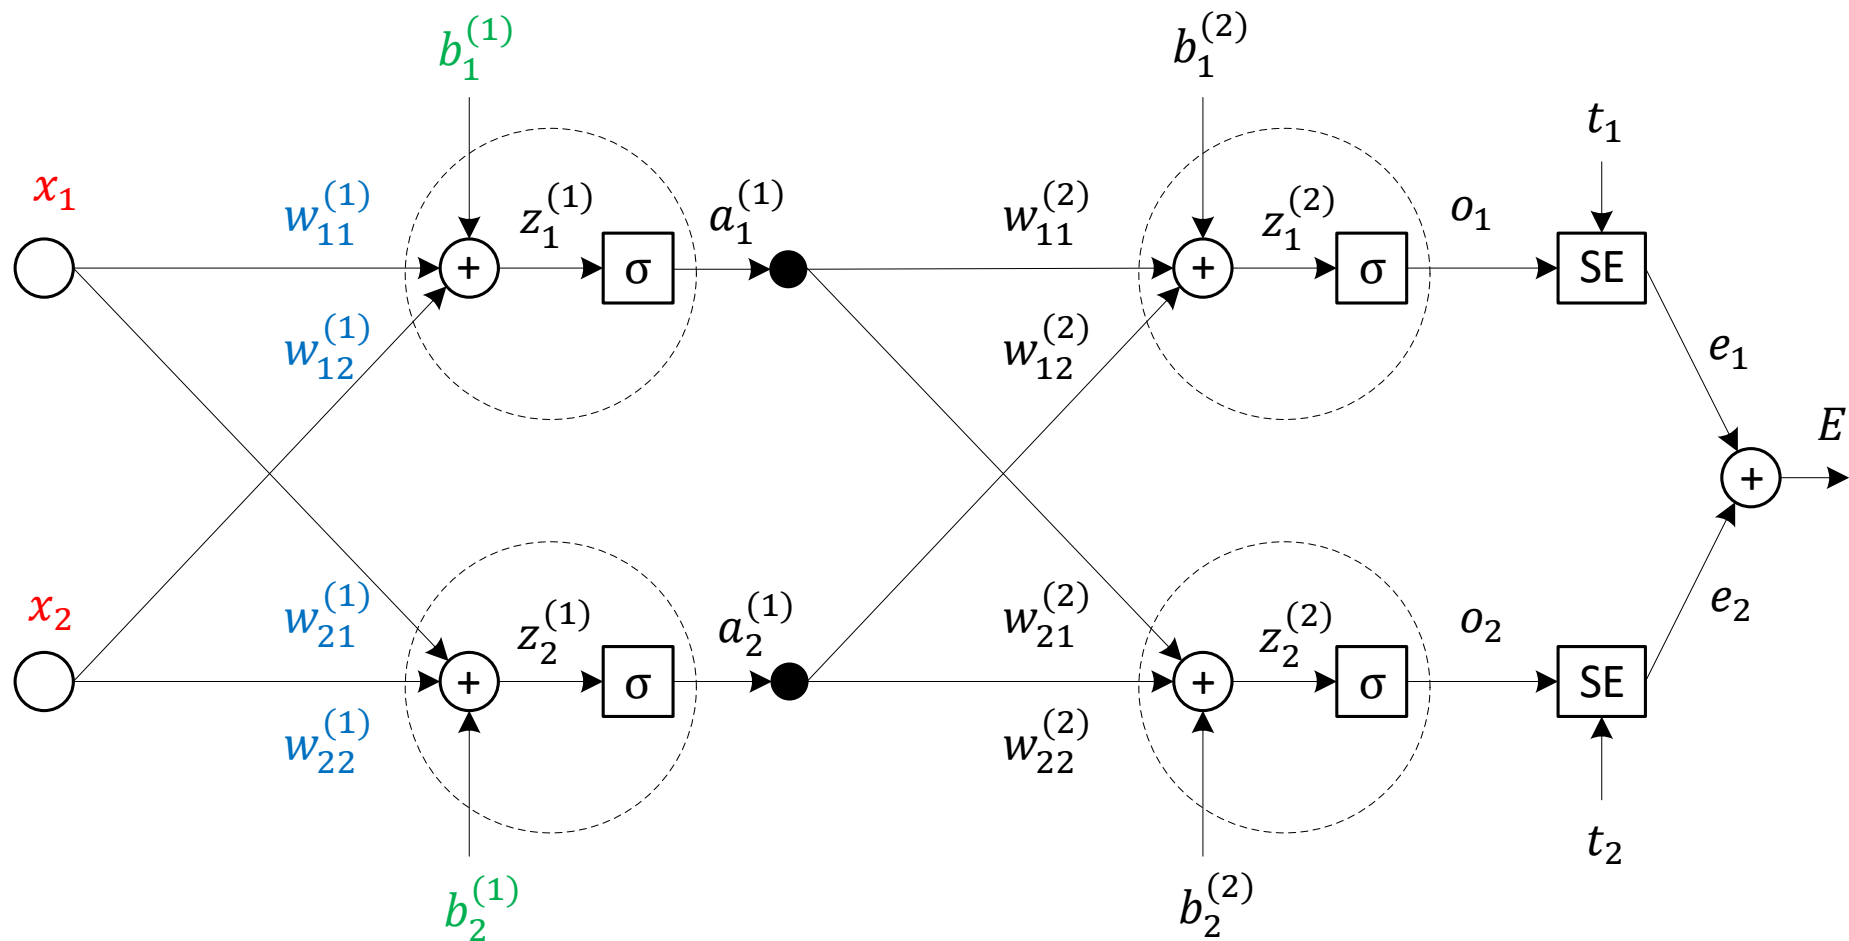
$$\mathbf{W}^{(1)} = \begin{bmatrix} w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{bmatrix}$$

– нейрон 1

– нейрон 2

вход 1

вход 2



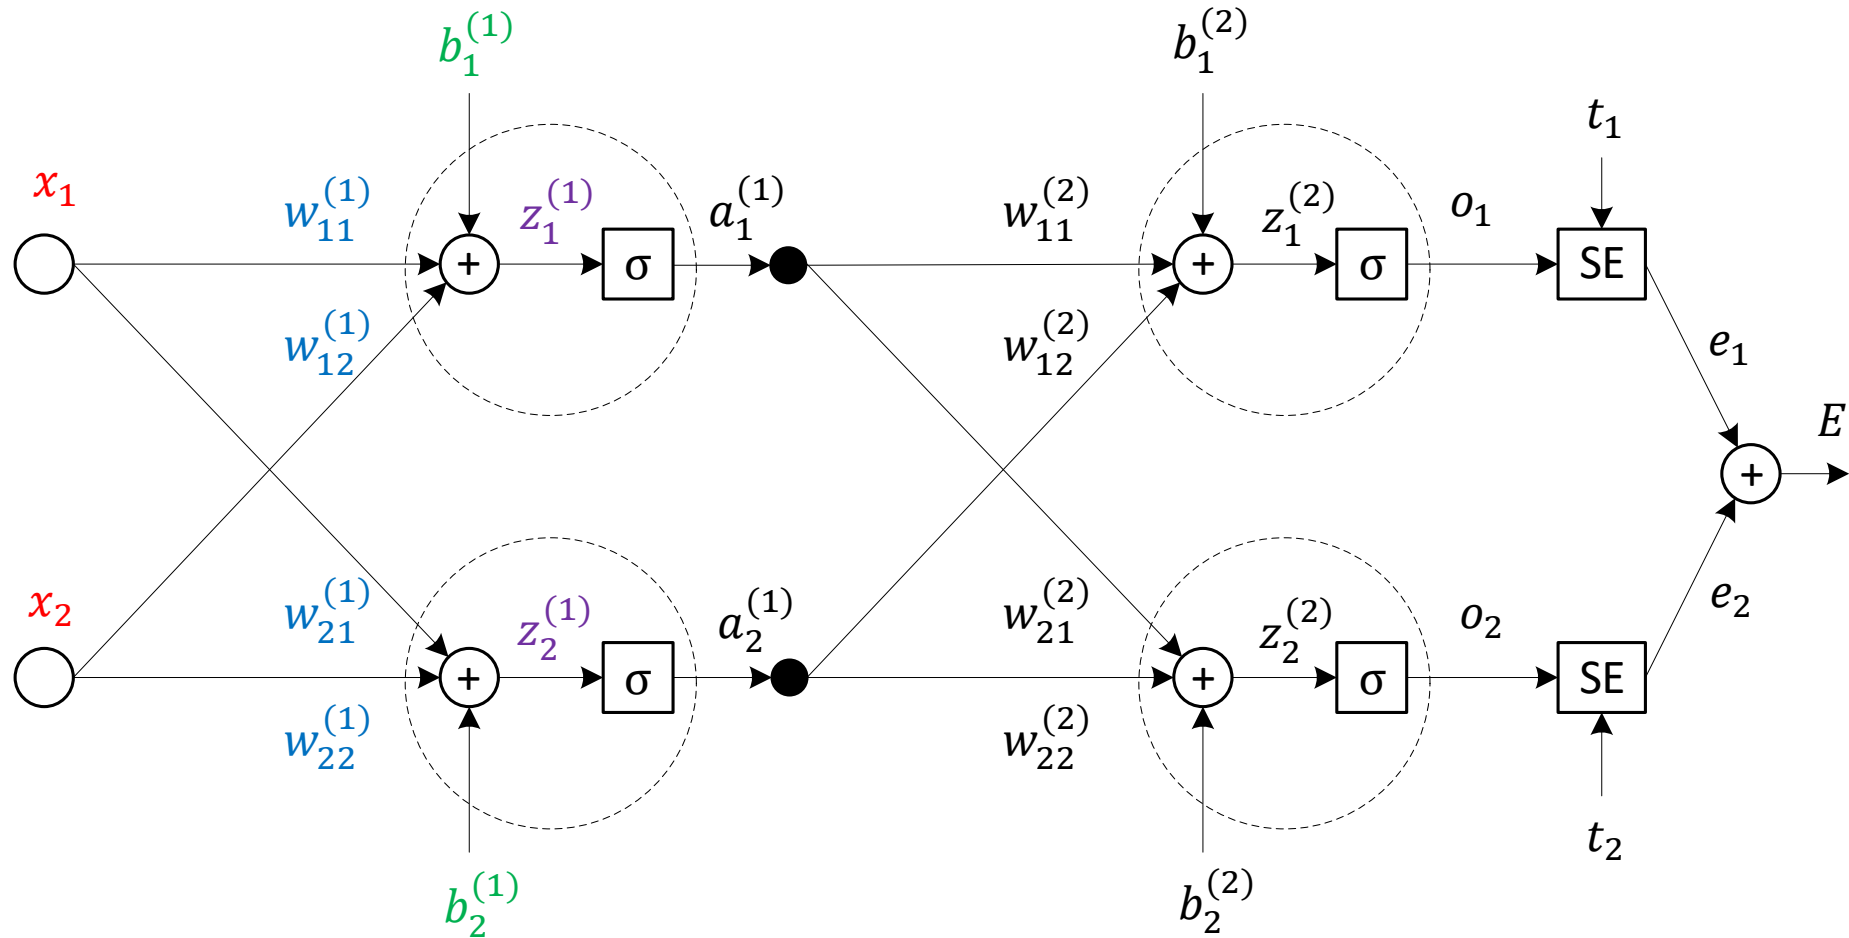
$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\mathbf{W}^{(1)} = \begin{bmatrix} w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{bmatrix} \begin{array}{l} \text{— нейрон 1} \\ \text{— нейрон 2} \end{array}$$

вход 1    вход 2

$$\mathbf{b}^{(1)} = \begin{bmatrix} b_1^{(1)} \\ b_2^{(1)} \end{bmatrix}$$

$$\mathbf{z}^{(1)} = \mathbf{W}^{(1)} \mathbf{x} + \mathbf{b}^{(1)}$$



$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

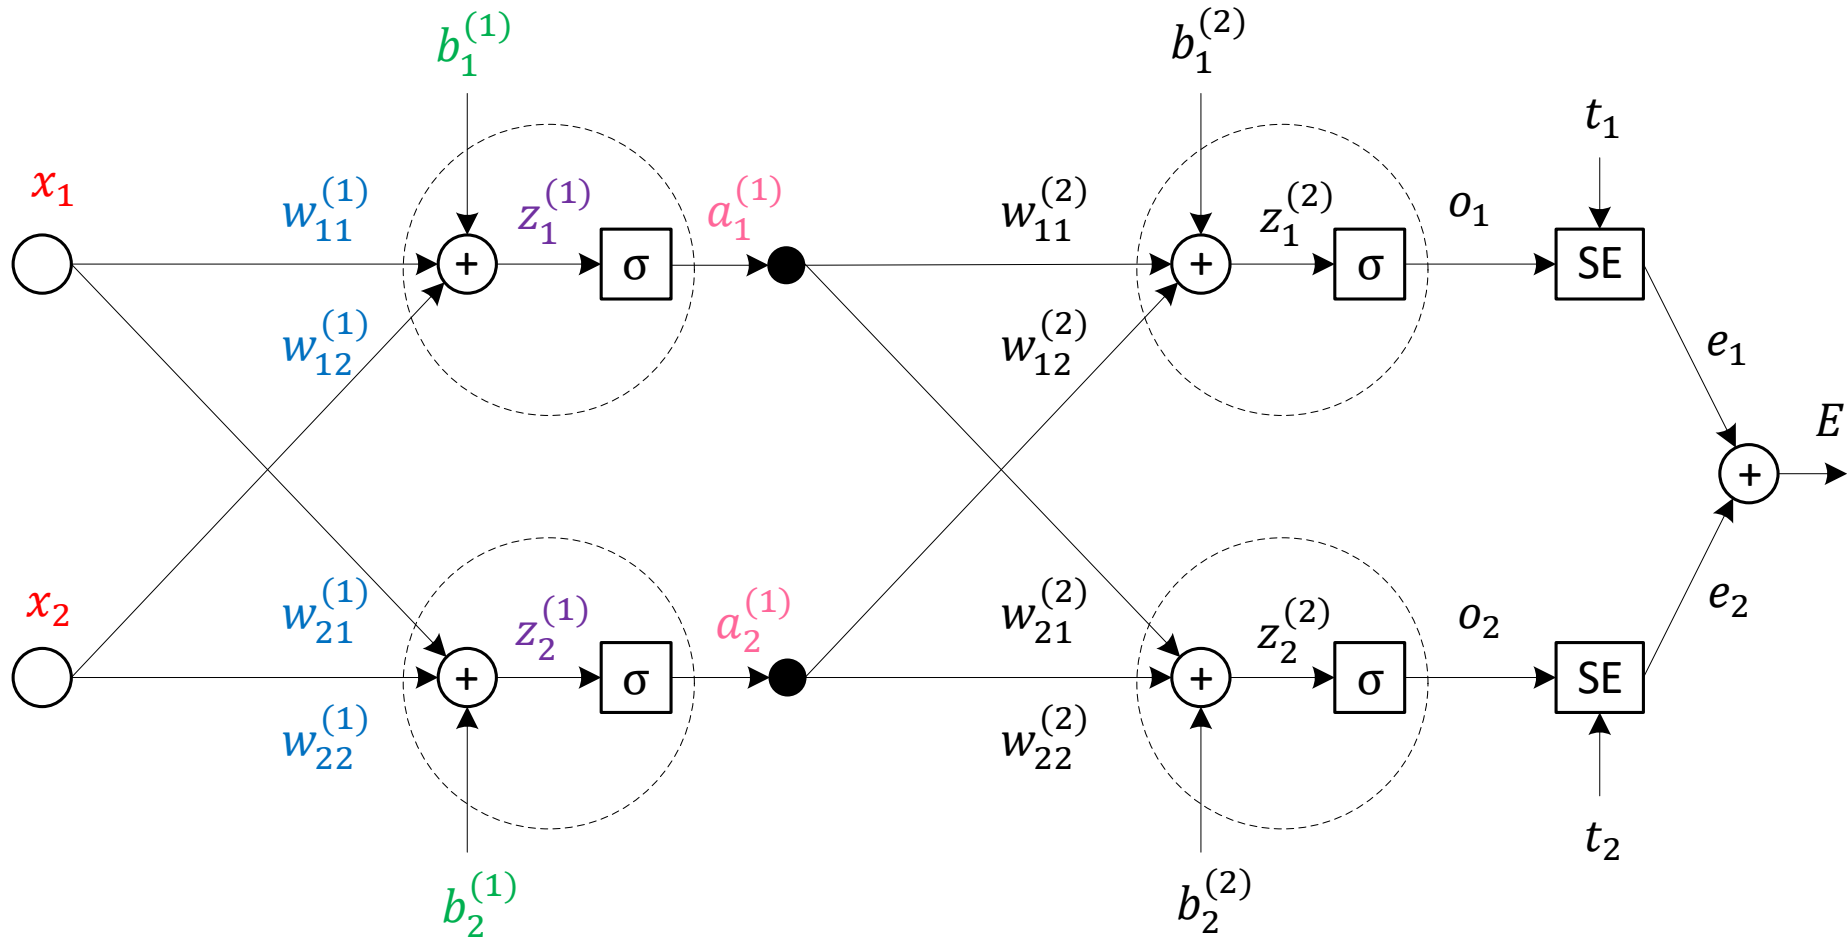
$$\mathbf{W}^{(1)} = \begin{bmatrix} w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{bmatrix}$$

– нейрон 1  
– нейрон 2

вход 1    вход 2

$$\mathbf{b}^{(1)} = \begin{bmatrix} b_1^{(1)} \\ b_2^{(1)} \end{bmatrix}$$

$$\mathbf{z}^{(1)} = \mathbf{W}^{(1)} \mathbf{x} + \mathbf{b}^{(1)} \quad \mathbf{a}^{(1)} = \sigma(\mathbf{z}^{(1)})$$



$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\mathbf{W}^{(1)} = \begin{bmatrix} w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{bmatrix} \begin{array}{l} \text{— нейрон 1} \\ \text{— нейрон 2} \end{array}$$

вход 1    вход 2

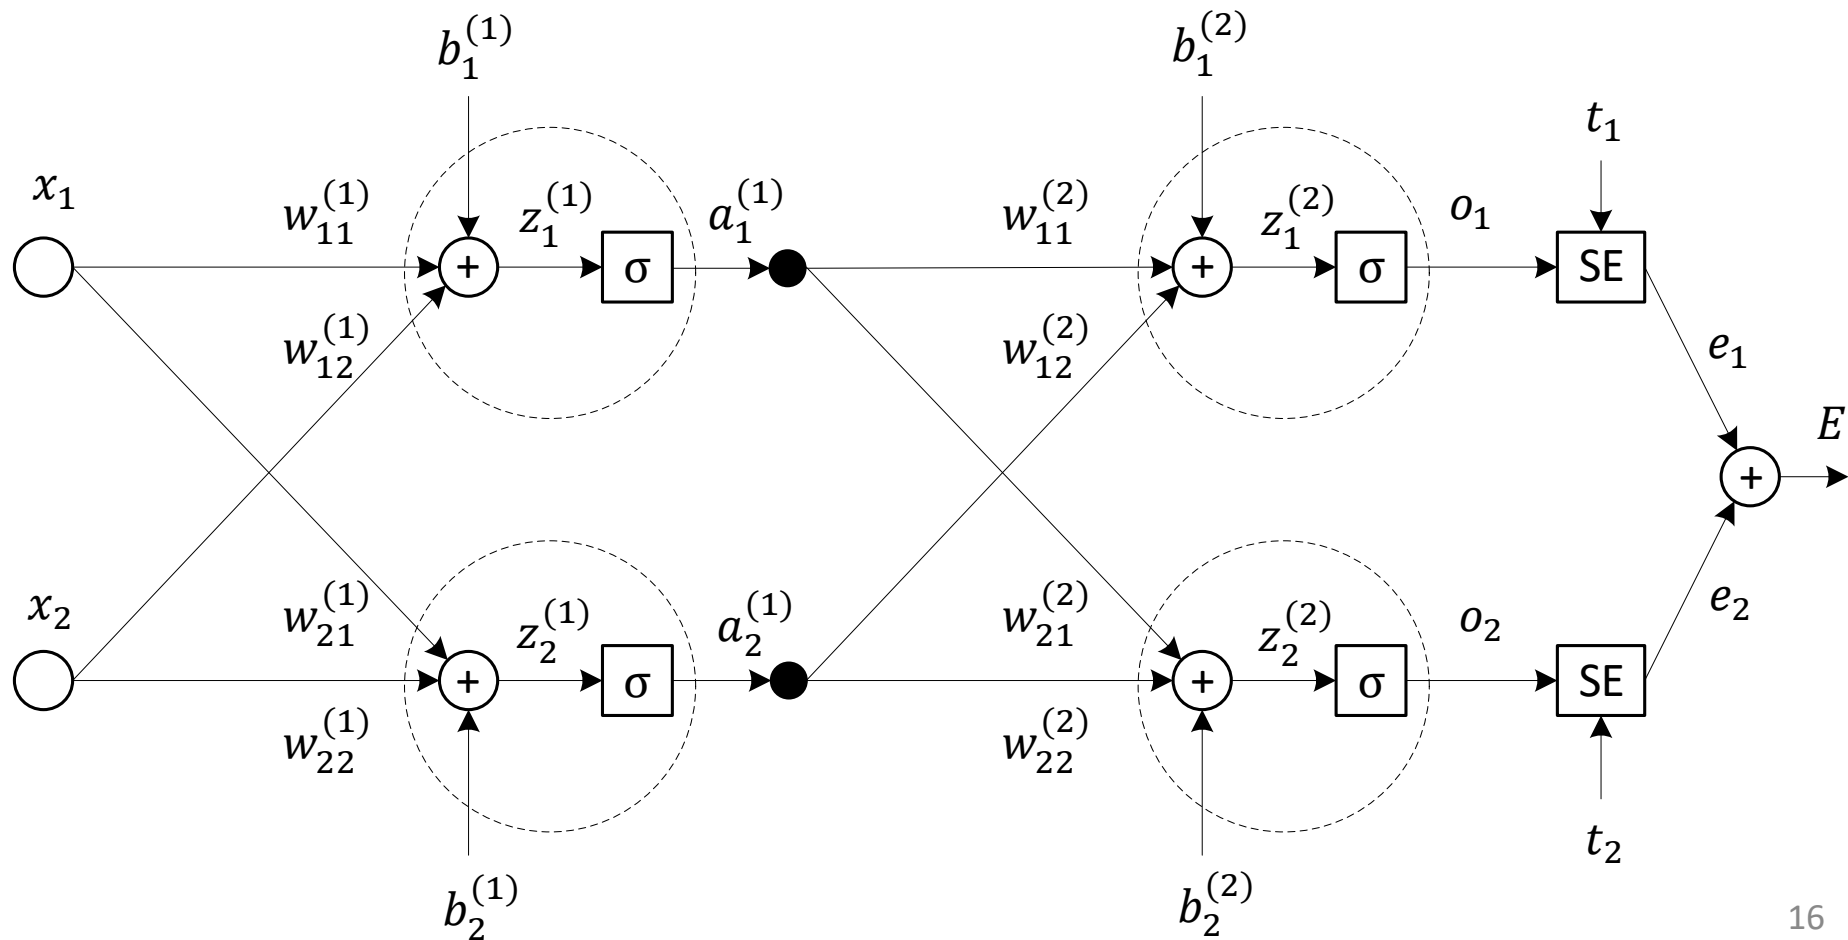
$$\mathbf{b}^{(1)} = \begin{bmatrix} b_1^{(1)} \\ b_2^{(1)} \end{bmatrix}$$

# Градиент

$$\nabla E_{w,b} = \left[ \frac{\partial E}{\partial w_{11}^{(1)}}, \frac{\partial E}{\partial w_{12}^{(1)}}, \dots, \frac{\partial E}{\partial w_{22}^{(2)}}, \frac{\partial E}{\partial b_1^{(1)}}, \dots, \frac{\partial E}{\partial b_2^{(2)}} \right]$$

- Значения градиента (частные производные) говорят о скорости изменения (чувствительности) функции в зависимости от изменения соответствующего веса  $\left( \frac{\Delta E}{\Delta w_{ij}} \right)$
- То есть градиент показывает, как наиболее эффективно изменить веса, чтобы максимально уменьшить значение функции потерь
- Backpropagation – алгоритм вычисления этого градиента

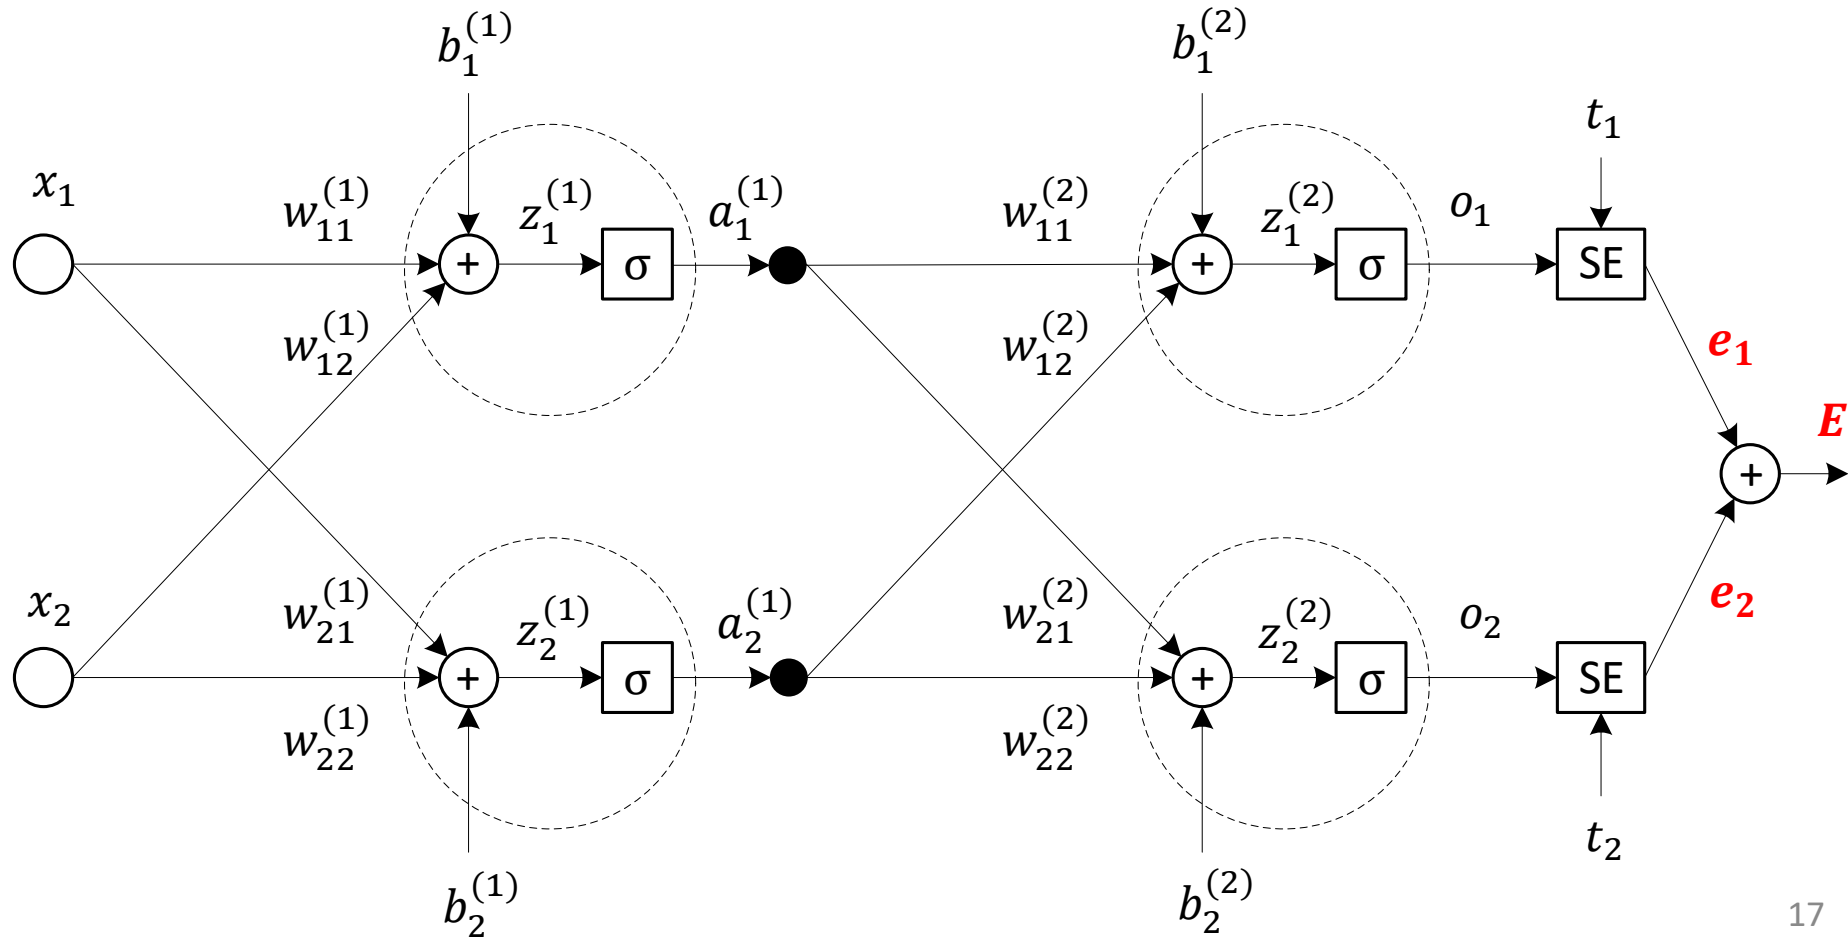
$$\nabla E_{\mathbf{w},\mathbf{b}} = \left[ \frac{\partial E}{\partial w_{11}^{(1)}}, \frac{\partial E}{\partial w_{12}^{(1)}}, \dots, \frac{\partial E}{\partial w_{22}^{(2)}}, \frac{\partial E}{\partial b_1^{(1)}}, \dots, \frac{\partial E}{\partial b_2^{(2)}} \right]$$





Квадратичная функция ошибки для одного примера:

$$E = \frac{1}{2} \|\vec{t} - \vec{o}\|^2 = \frac{1}{2} \sum_j (t_j - o_j)^2 = \frac{1}{2} (t_1 - o_1)^2 + \frac{1}{2} (t_2 - o_2)^2 = e_1 + e_2$$

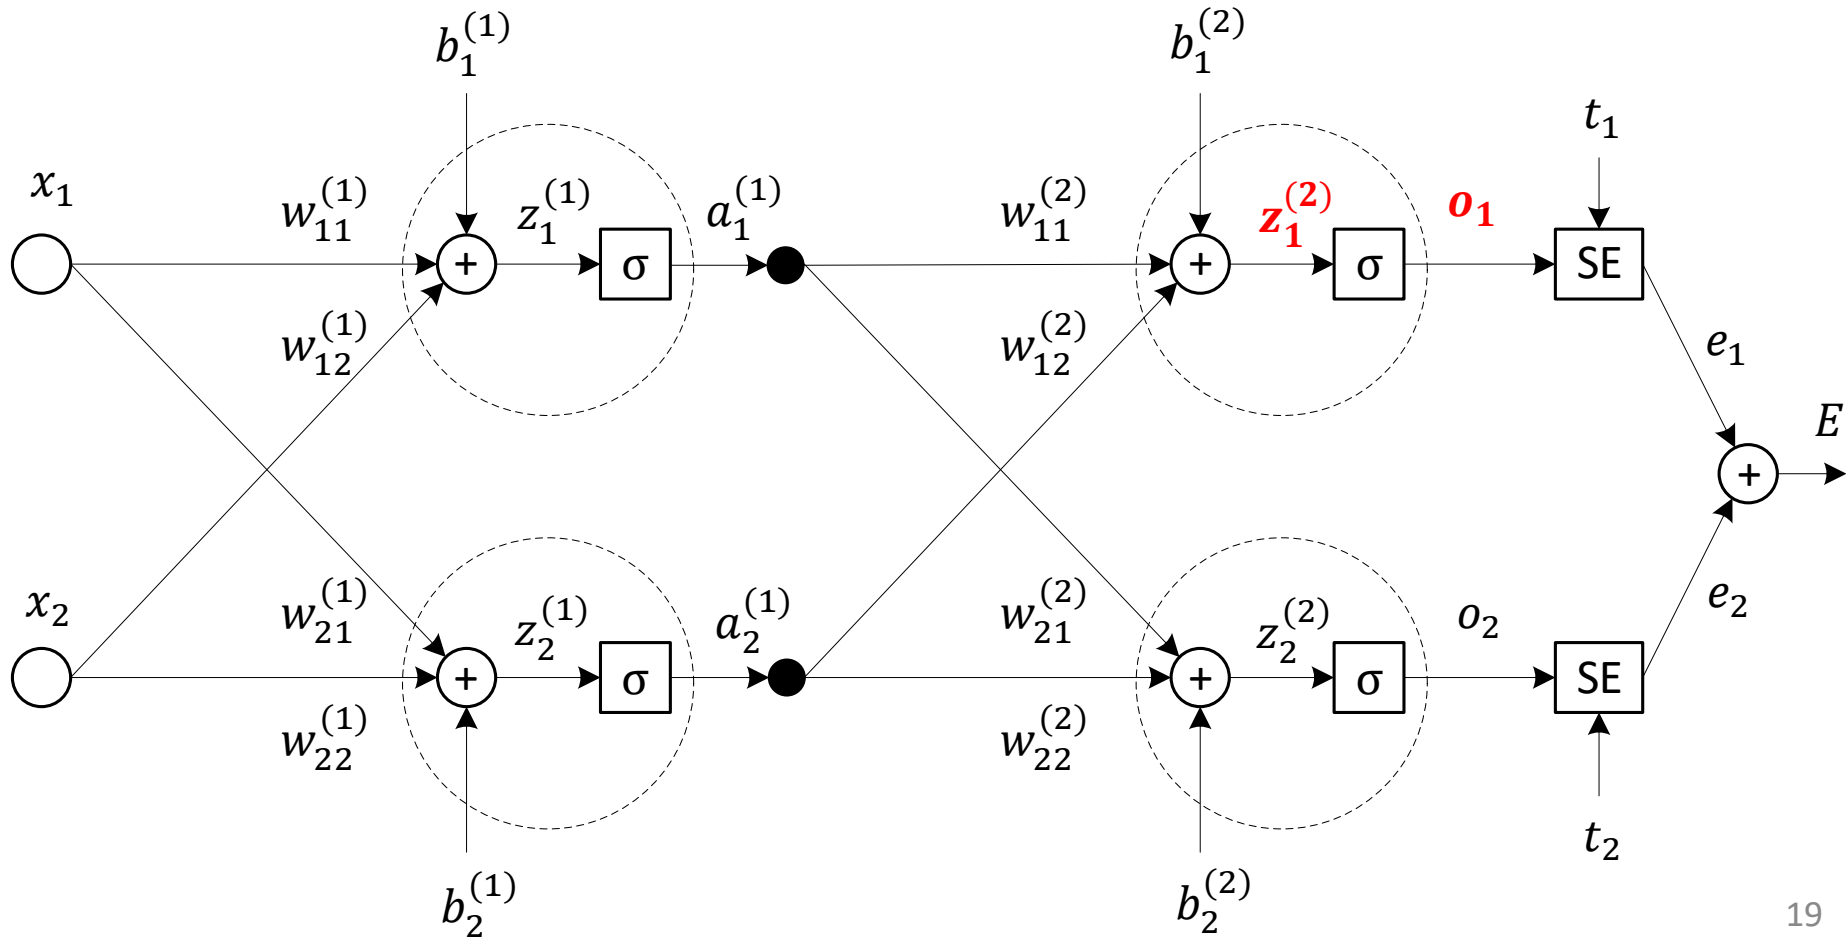


# Градиент

$$\nabla E_{\mathbf{w}, \mathbf{b}} = \left[ \frac{\partial E}{\partial w_{11}^{(1)}}, \frac{\partial E}{\partial w_{12}^{(1)}}, \dots, \frac{\partial E}{\partial w_{22}^{(2)}}, \frac{\partial E}{\partial b_1^{(1)}}, \dots, \frac{\partial E}{\partial b_2^{(2)}} \right]$$

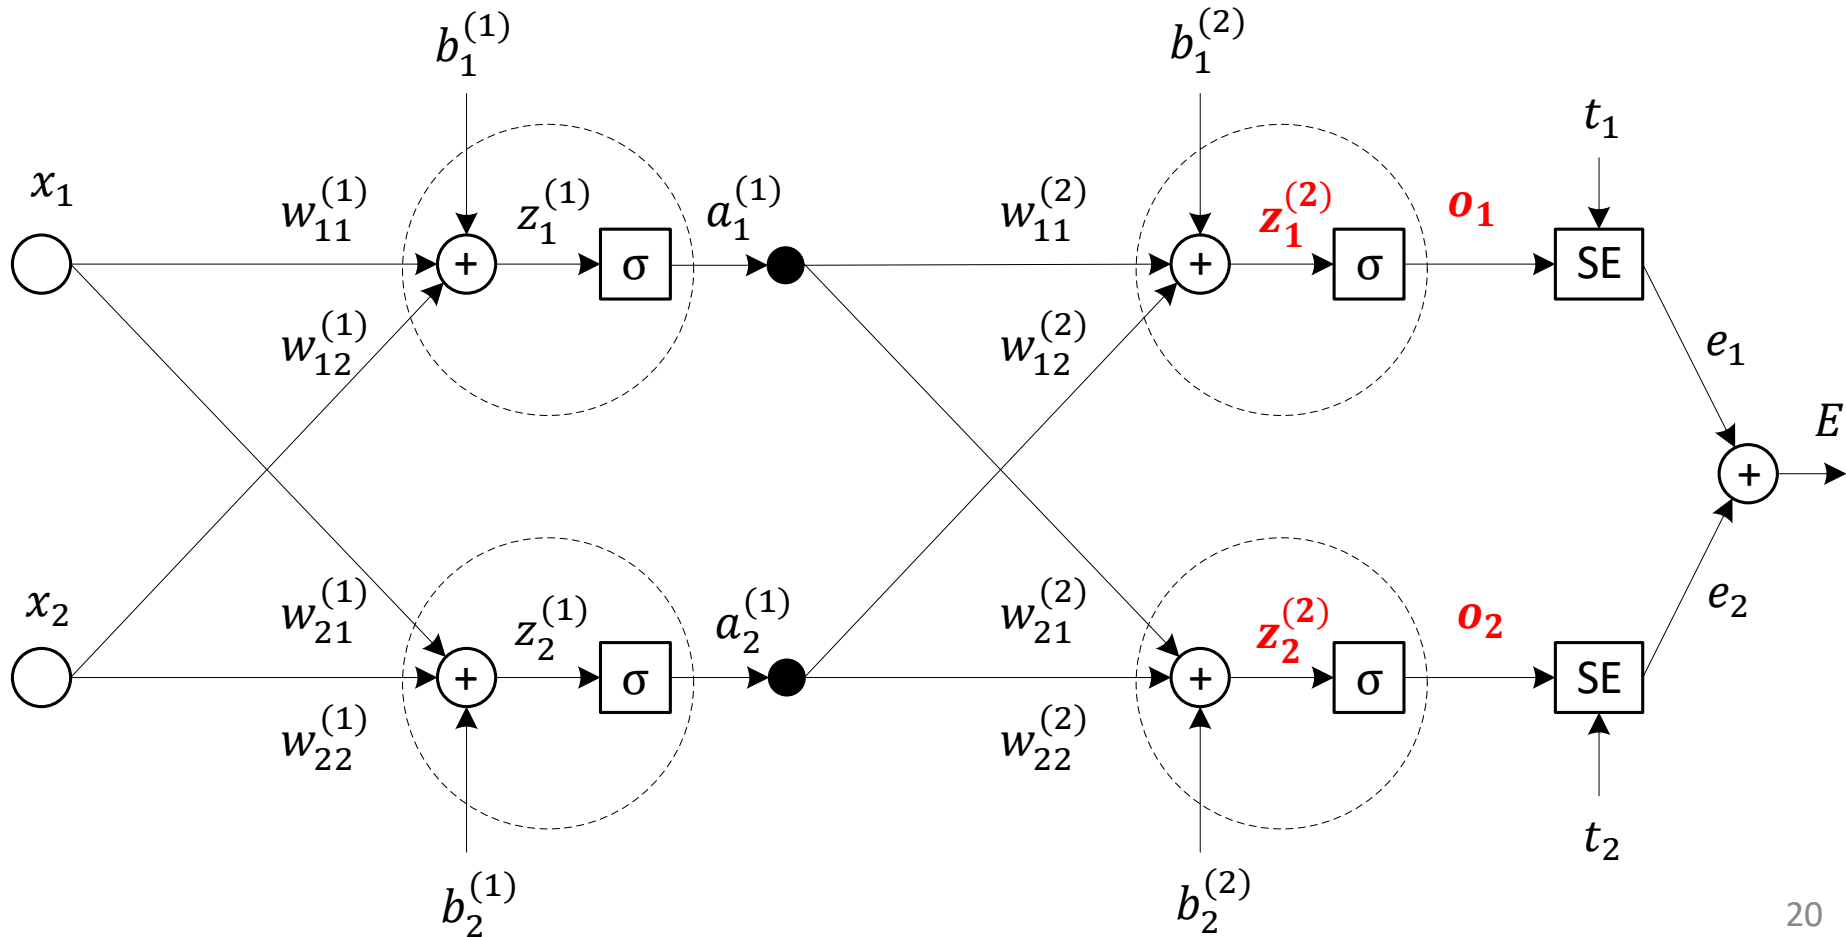
$$E = e_1 + e_2 = \frac{1}{2} (t_1 - o_1)^2 + \frac{1}{2} (t_2 - o_2)^2$$

$$o_1 = \sigma \left( \mathbf{z}_1^{(2)} \right) = \sigma \left( w_{11}^{(2)} a_1^{(1)} + w_{12}^{(2)} a_2^{(1)} + b_1^{(2)} \right)$$



$$o_1 = \sigma \left( \mathbf{z}_1^{(2)} \right) = \sigma \left( w_{11}^{(2)} a_1^{(1)} + w_{12}^{(2)} a_2^{(1)} + b_1^{(2)} \right)$$

$$o_2 = \sigma \left( \mathbf{z}_2^{(2)} \right) = \sigma \left( w_{21}^{(2)} a_1^{(1)} + w_{22}^{(2)} a_2^{(1)} + b_2^{(2)} \right)$$



# Градиент

$$\nabla E_{\mathbf{w}, \mathbf{b}} = \left[ \frac{\partial E}{\partial w_{11}^{(1)}}, \frac{\partial E}{\partial w_{12}^{(1)}}, \dots, \frac{\partial E}{\partial w_{22}^{(2)}}, \frac{\partial E}{\partial b_1^{(1)}}, \dots, \frac{\partial E}{\partial b_2^{(2)}} \right]$$

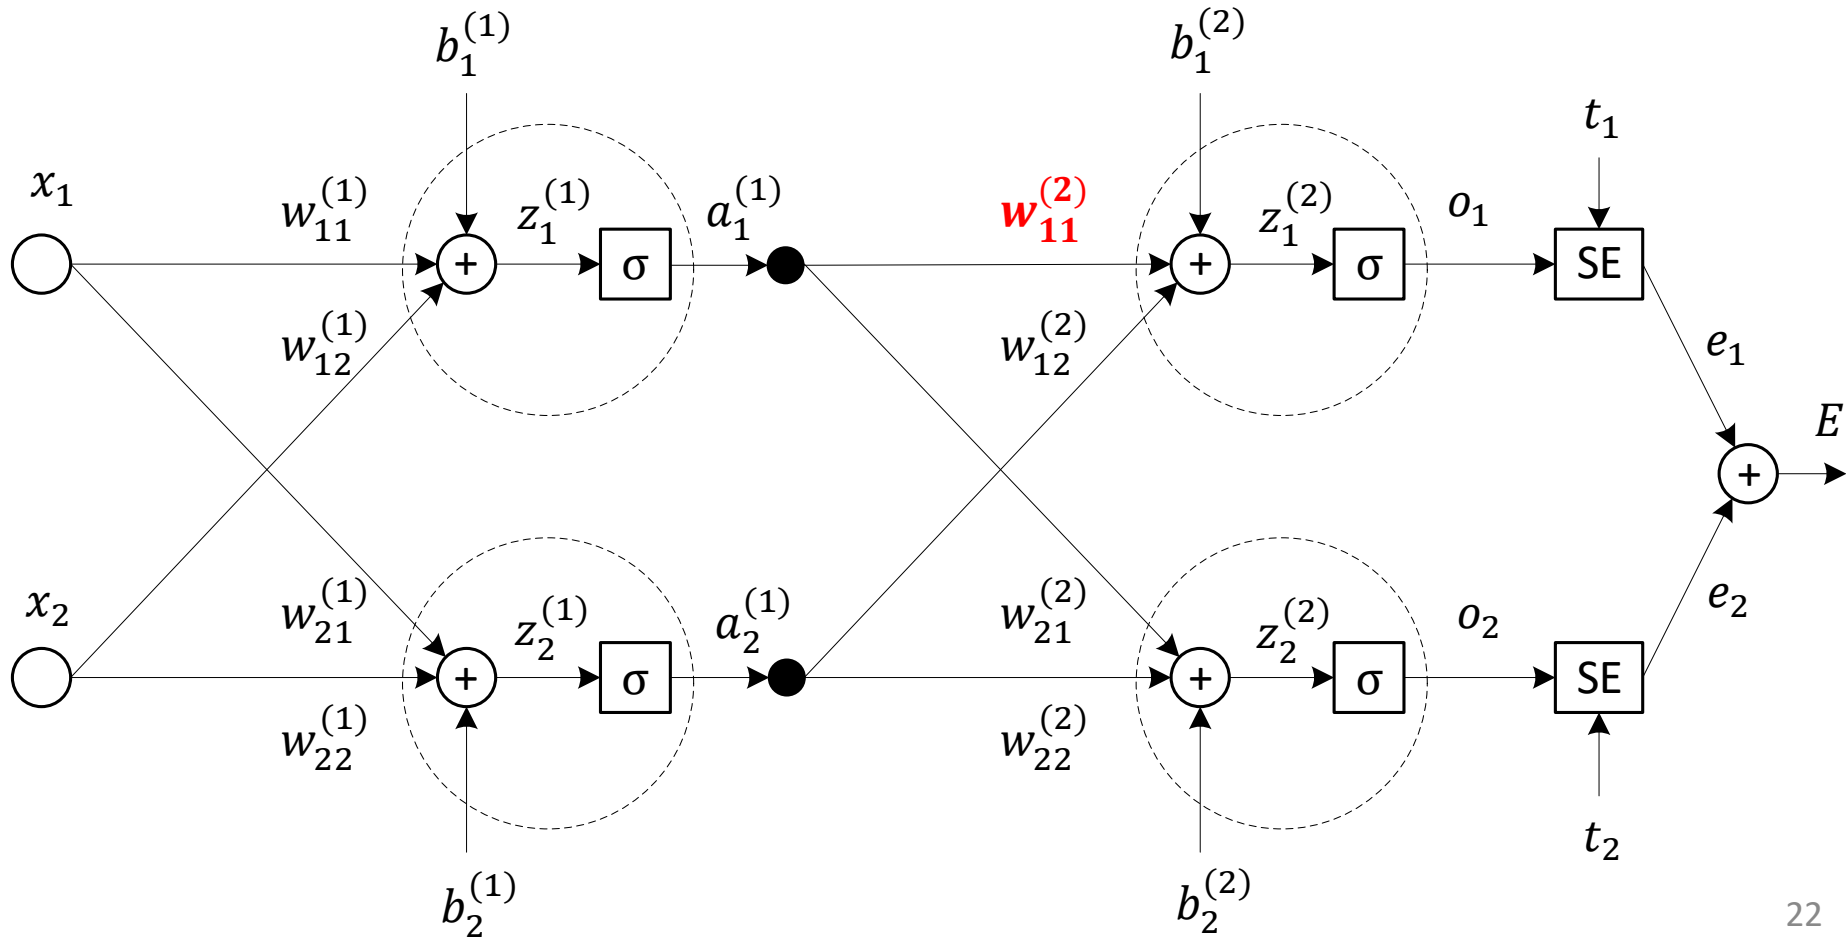
$$E = e_1 + e_2 = \frac{1}{2} (t_1 - o_1)^2 + \frac{1}{2} (t_2 - o_2)^2$$

$$o_1 = \sigma \left( z_1^{(2)} \right) = \sigma \left( w_{11}^{(2)} a_1^{(1)} + w_{12}^{(2)} a_2^{(1)} + b_1^{(2)} \right)$$

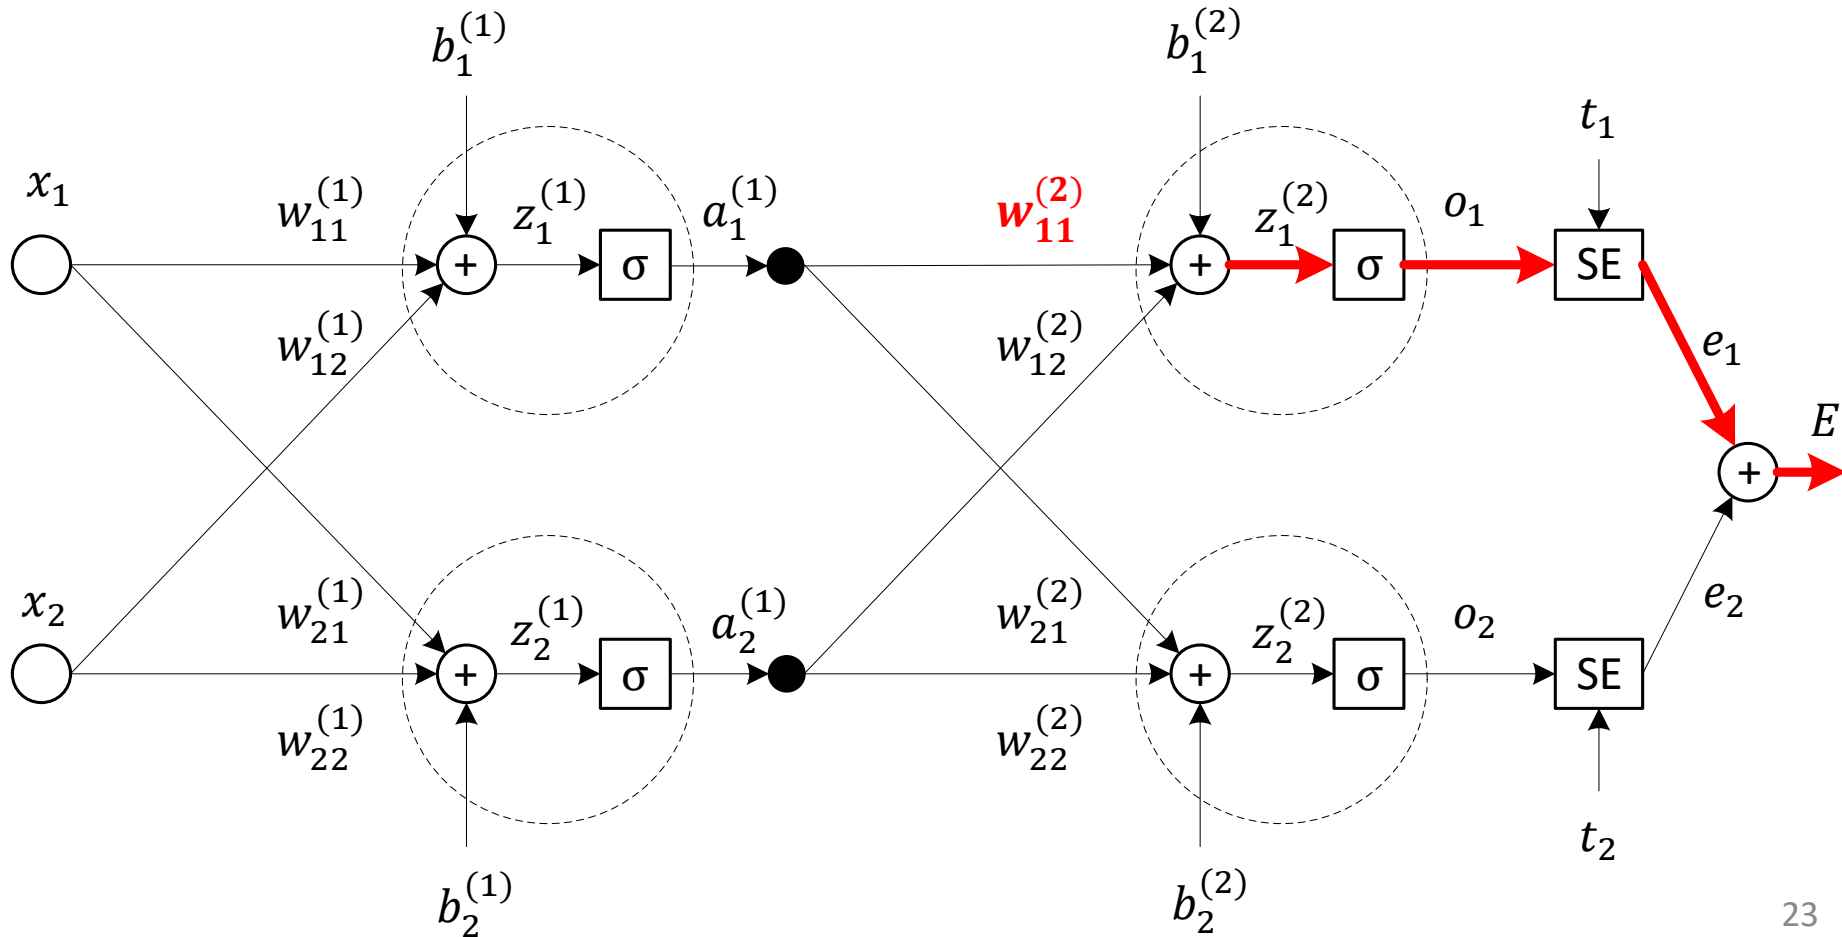
$$o_2 = \sigma \left( z_2^{(2)} \right) = \sigma \left( w_{21}^{(2)} a_1^{(1)} + w_{22}^{(2)} a_2^{(1)} + b_2^{(2)} \right)$$

# Градиент выходного слоя

$$\frac{\partial E}{\partial w_{11}^{(2)}} = ?$$



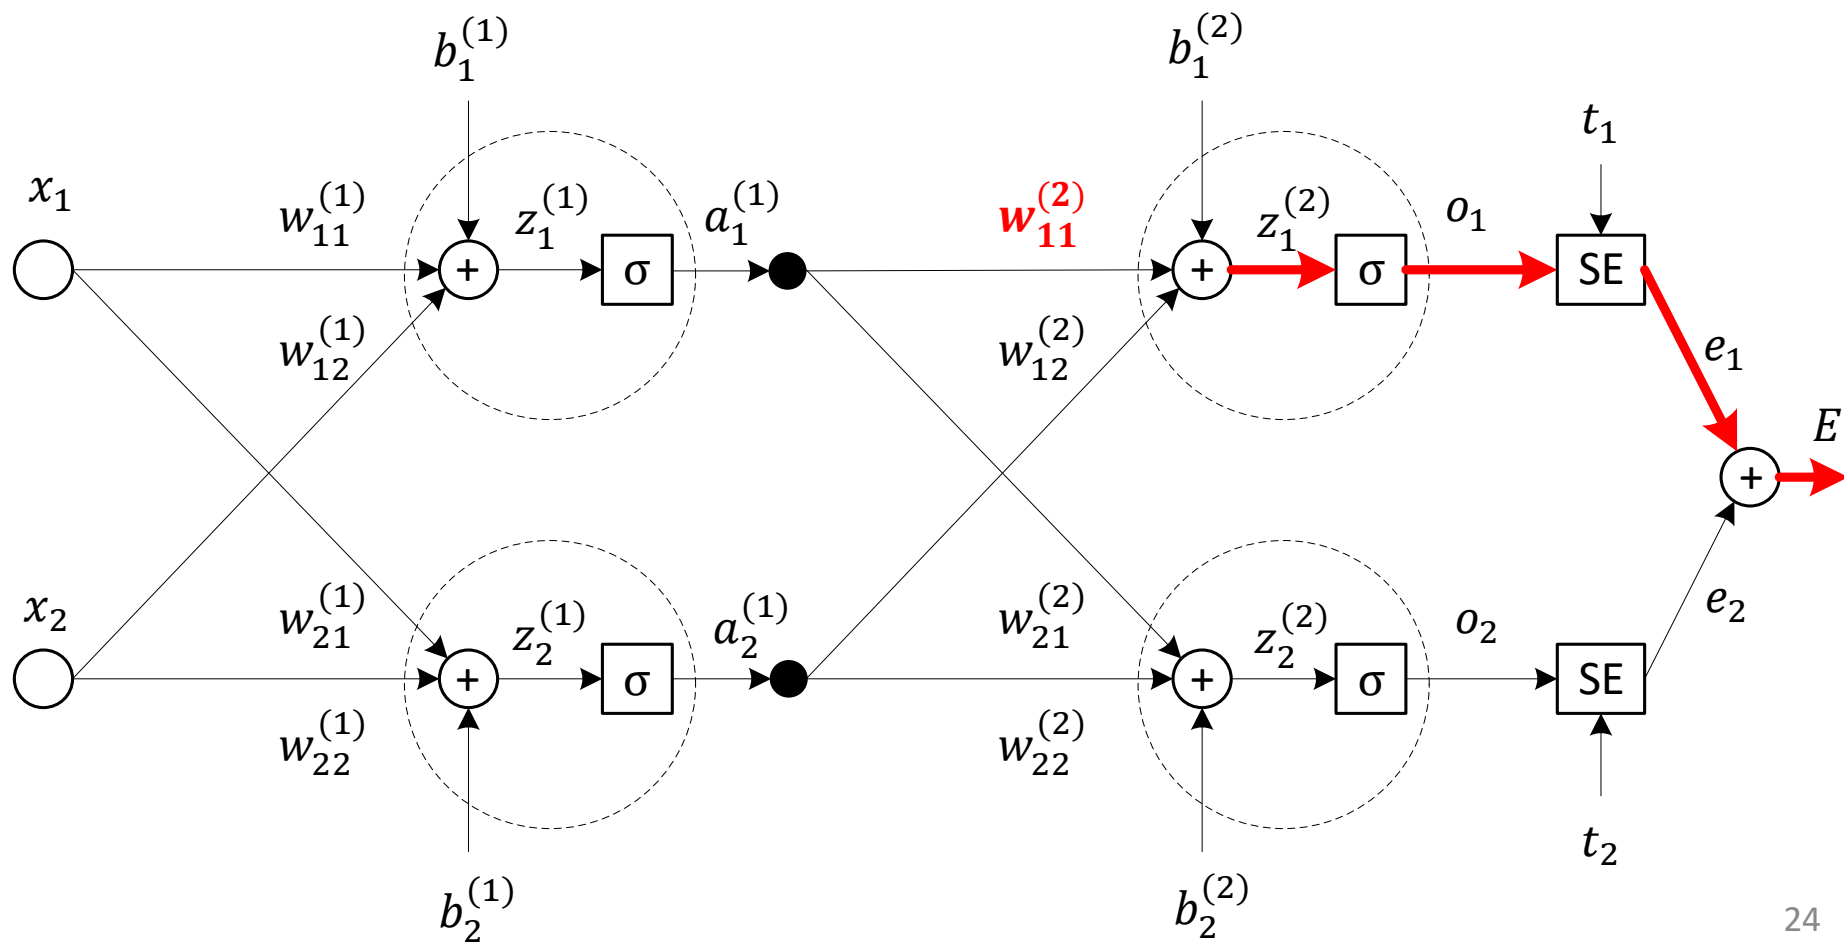
$$\frac{\partial E}{\partial w_{11}^{(2)}} = \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial w_{11}^{(2)}} \quad - \text{цепное правило, (chain rule)}$$



$$\frac{\partial E}{\partial w_{11}^{(2)}} = \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial w_{11}^{(2)}}$$

$$E = e_1 + e_2 = \frac{1}{2}(t_1 - o_1)^2 + \frac{1}{2}(t_2 - o_2)^2$$

$$\frac{\partial E}{\partial o_1} = -(t_1 - o_1)$$



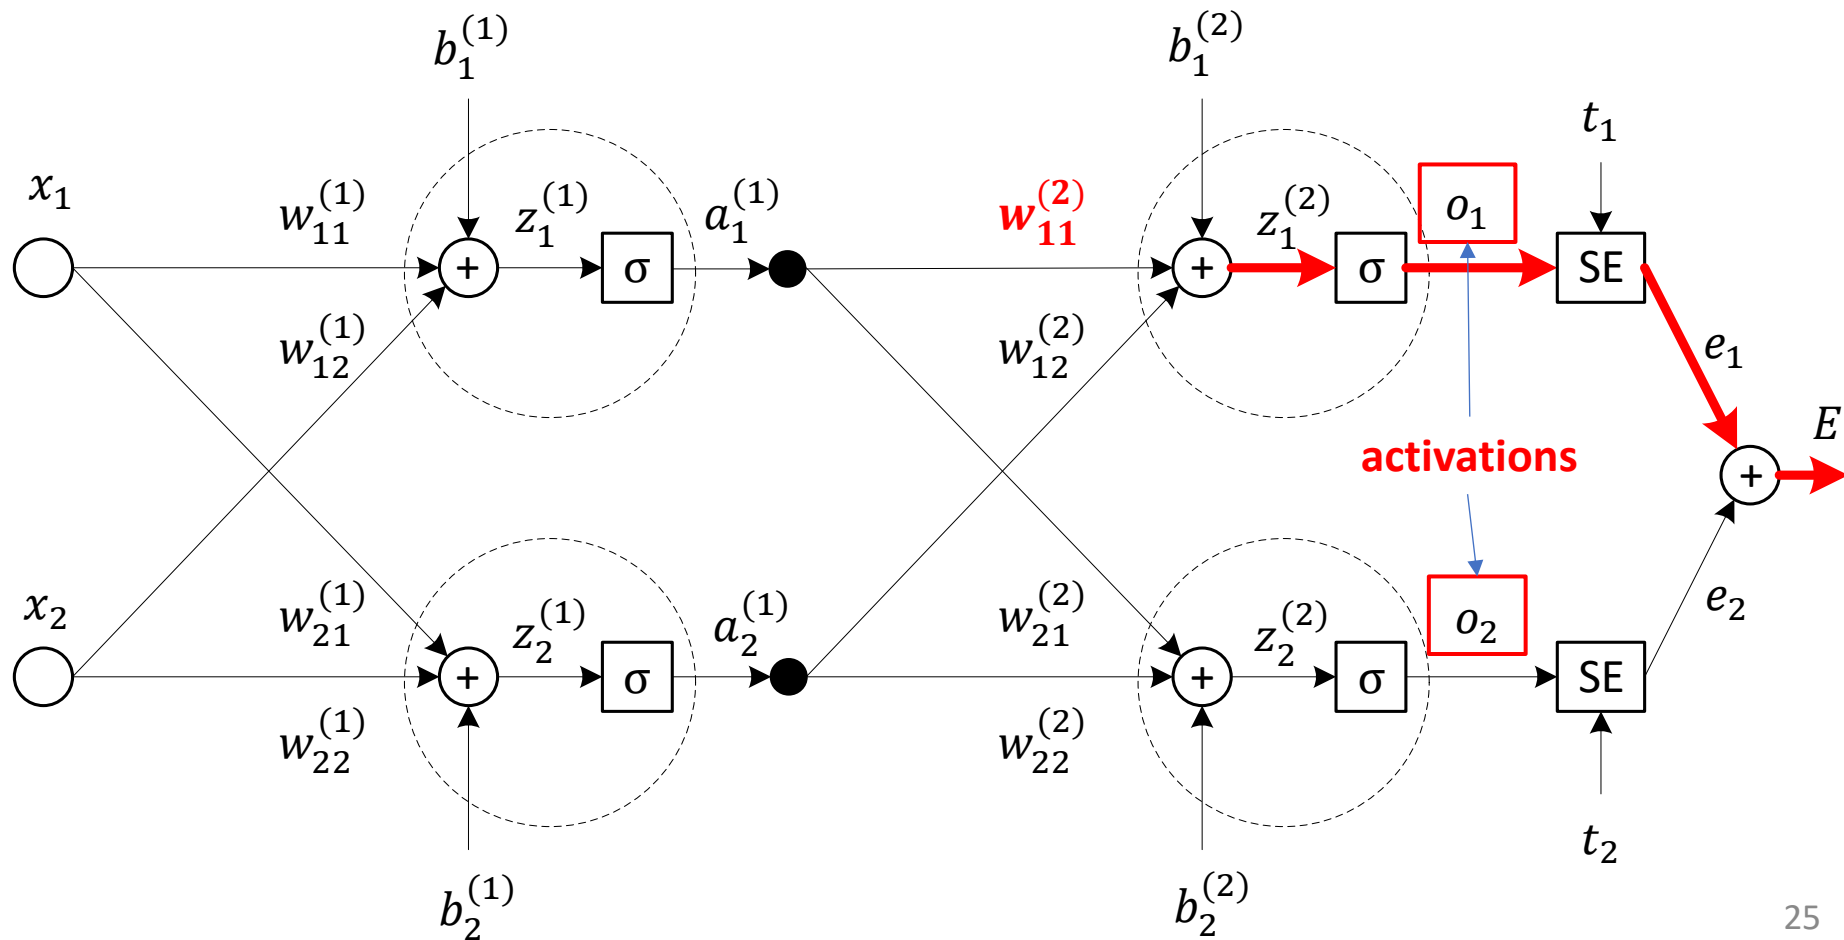


$$\frac{\partial E}{\partial w_{11}^{(2)}} = \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial w_{11}^{(2)}}$$

$$o_1 = \sigma(z_1^{(2)})$$

Храним активации  
(а  $z_j^{(i)}$  – не храним)

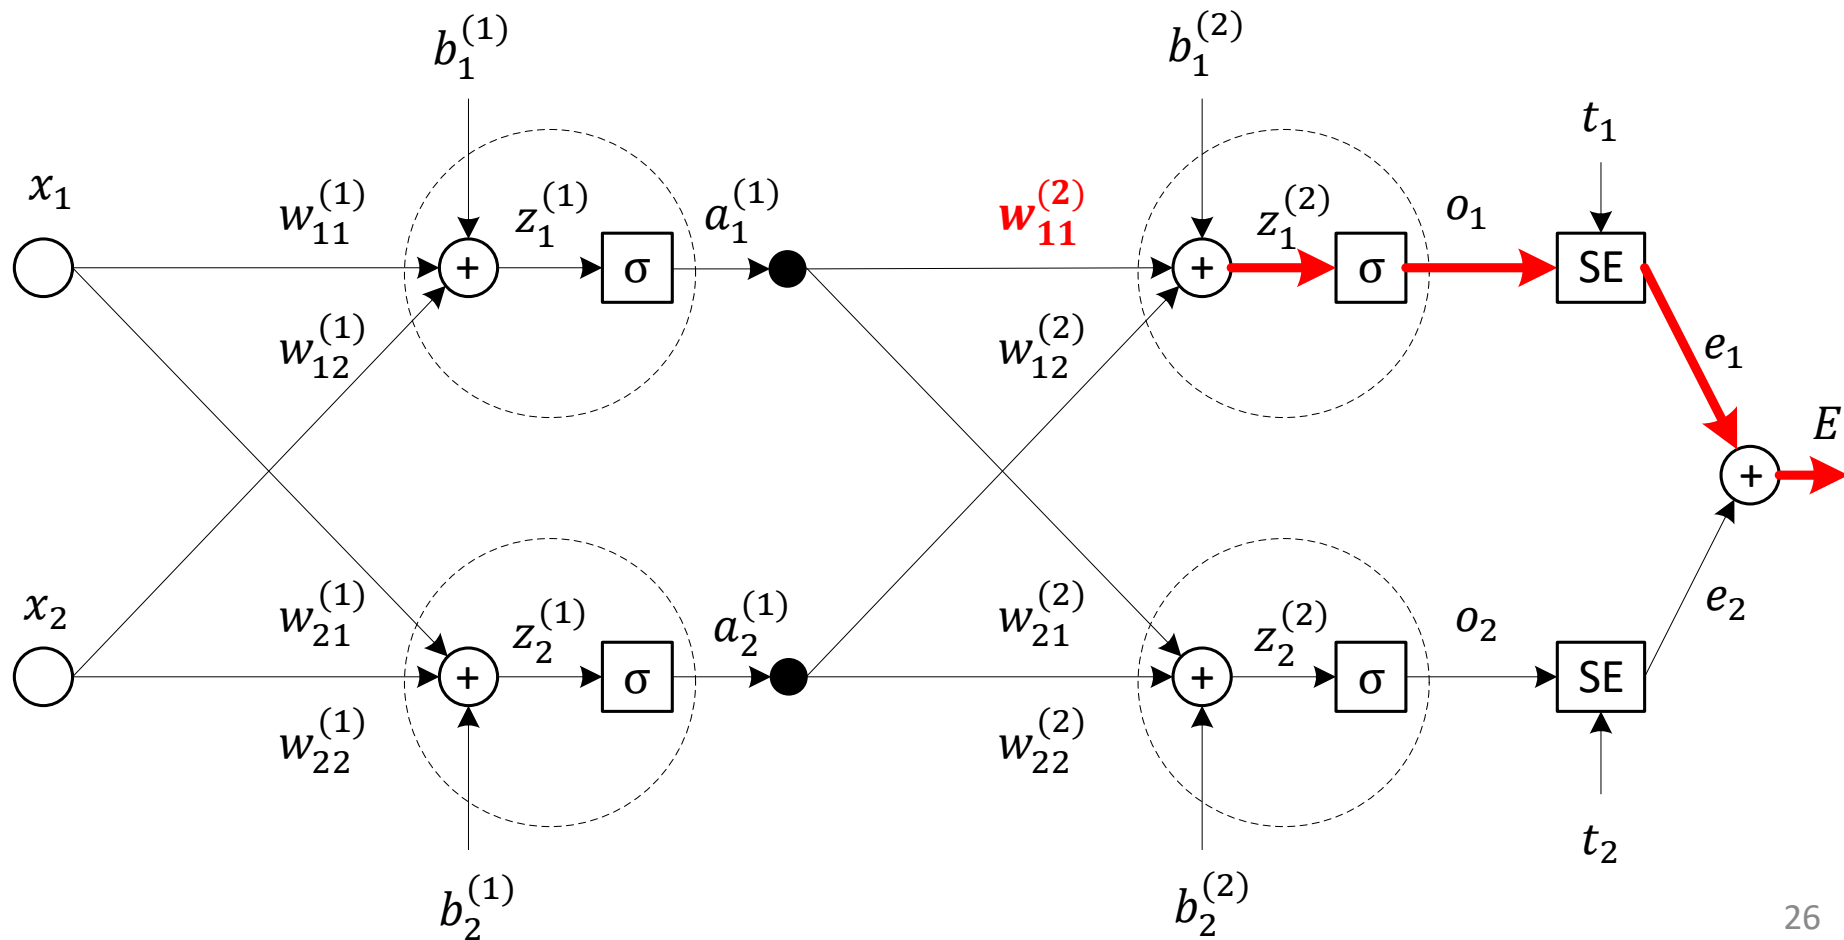
$$\frac{\partial o_1}{\partial z_1^{(2)}} = o_1(1 - o_1)$$



$$\frac{\partial E}{\partial w_{11}^{(2)}} = \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial w_{11}^{(2)}}$$

$$z_1^{(2)} = w_{11}^{(2)} a_1^{(1)} + w_{12}^{(2)} a_2^{(1)} + b_1^{(2)}$$

$$\frac{\partial z_1^{(2)}}{\partial w_{11}^{(2)}} = a_1^{(1)}$$



# Градиент выходного слоя

$$\frac{\partial E}{\partial w_{11}^{(2)}} = \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial w_{11}^{(2)}} = -(t_1 - o_1) o_1 (1 - o_1) a_1^{(1)}$$

# Градиент выходного слоя

$$\frac{\partial E}{\partial w_{11}^{(2)}} = \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial w_{11}^{(2)}} = -(t_1 - o_1) o_1 (1 - o_1) a_1^{(1)}$$

$$\frac{\partial E}{\partial w_{12}^{(2)}} = \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial w_{12}^{(2)}} = -(t_1 - o_1) o_1 (1 - o_1) a_2^{(1)}$$

$$\frac{\partial E}{\partial b_1^{(2)}} = \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial b_1^{(2)}} = -(t_1 - o_1) o_1 (1 - o_1)$$

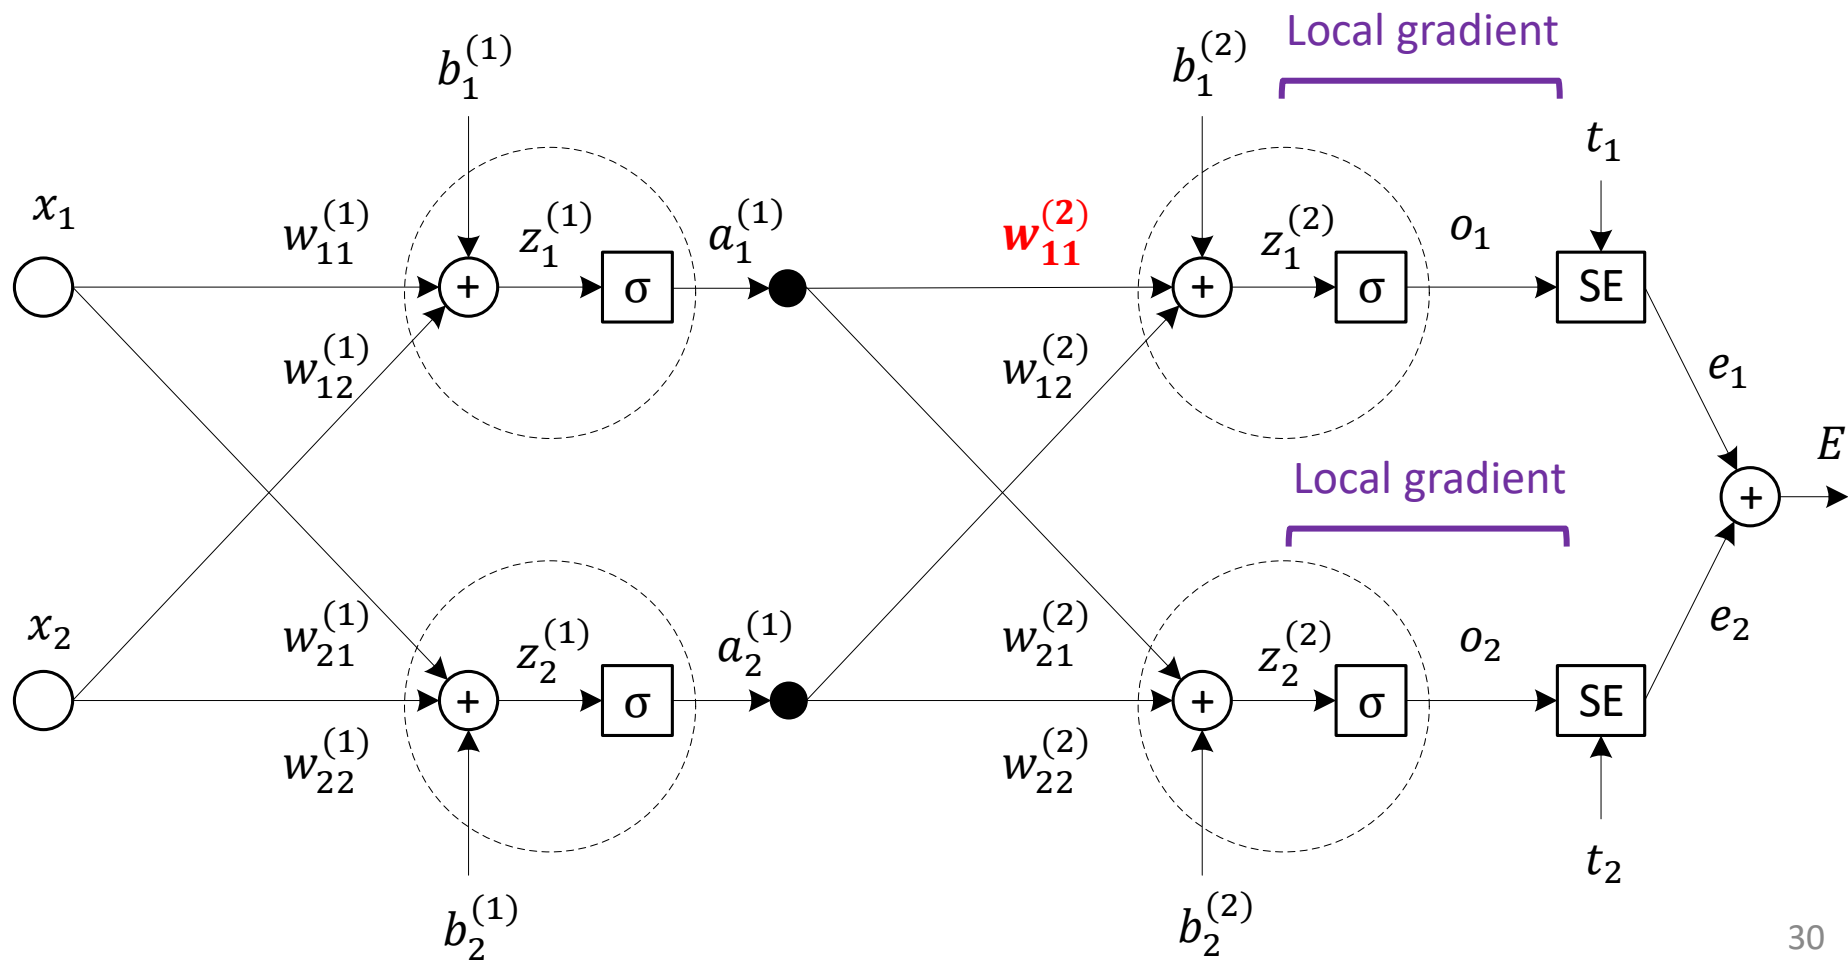
# Градиент выходного слоя

$$\begin{aligned}
 \frac{\partial E}{\partial w_{11}^{(2)}} &= \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial w_{11}^{(2)}} = -(t_1 - o_1) o_1 (1 - o_1) a_1^{(1)} = \delta_1^{(2)} a_1^{(1)} \\
 \frac{\partial E}{\partial w_{12}^{(2)}} &= \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial w_{12}^{(2)}} = -(t_1 - o_1) o_1 (1 - o_1) a_2^{(1)} = \delta_1^{(2)} a_2^{(1)} \\
 \frac{\partial E}{\partial b_1^{(2)}} &= \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial b_1^{(2)}} = -(t_1 - o_1) o_1 (1 - o_1) = \delta_1^{(2)}
 \end{aligned}$$

$$\delta_1^{(2)} = \frac{\partial E}{\partial z_1^{(2)}}$$

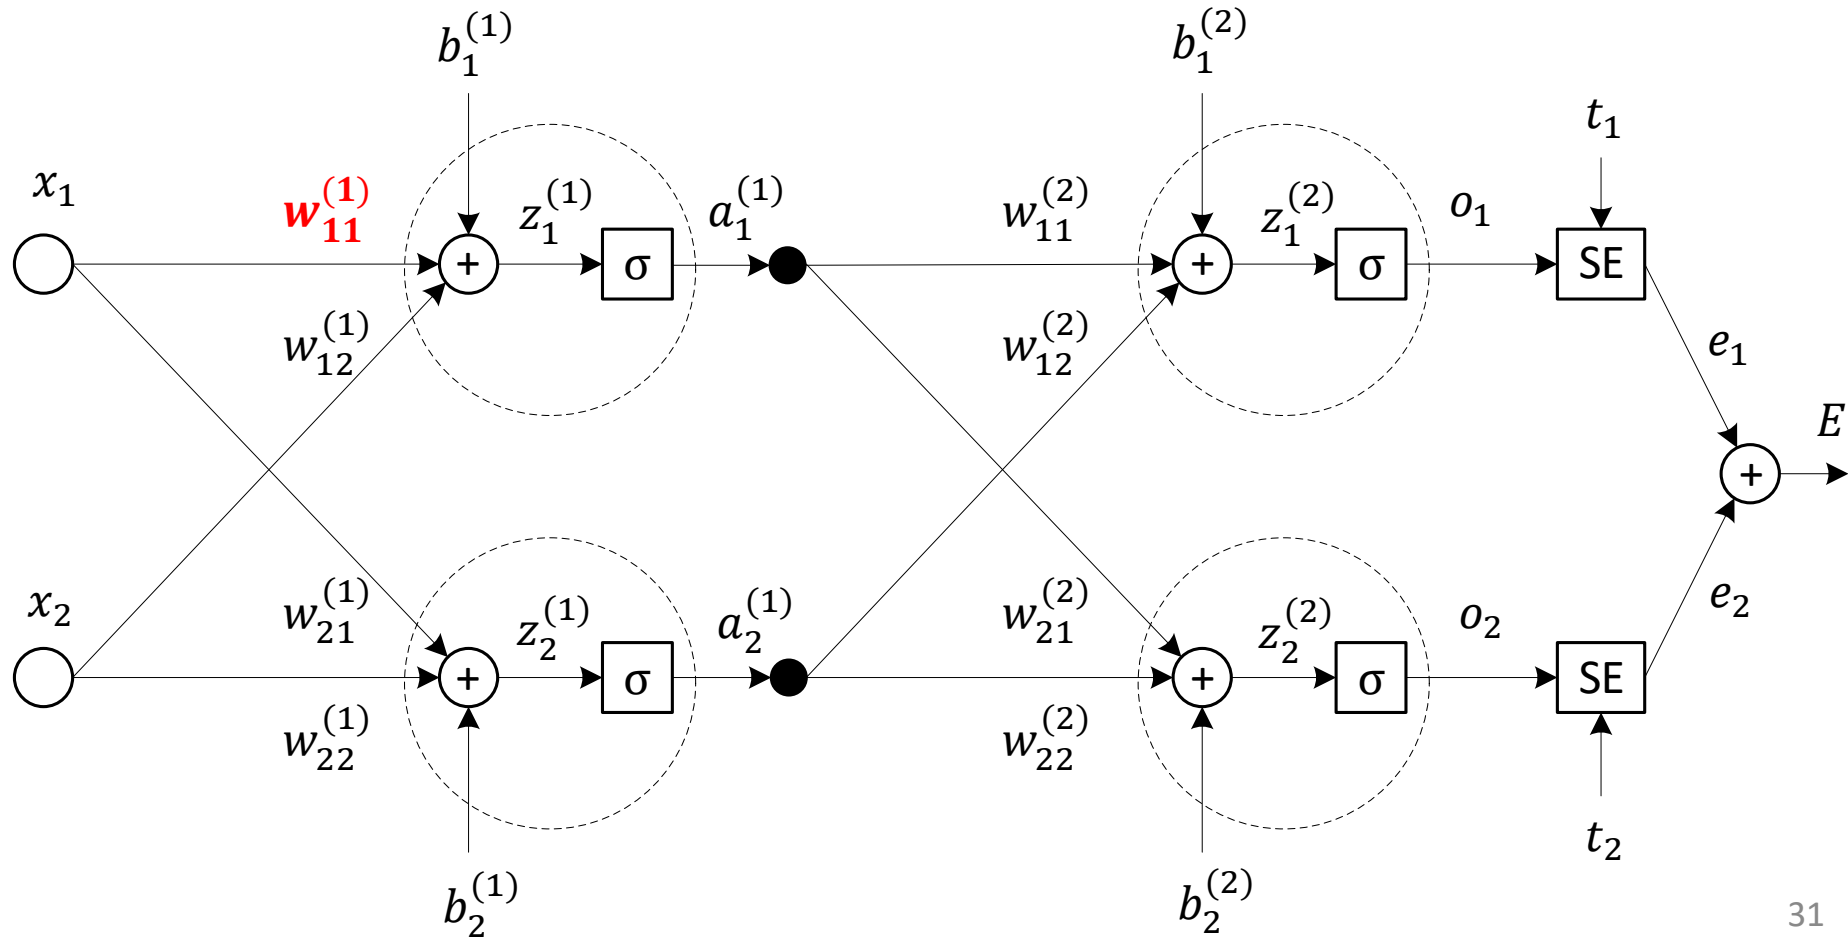
Local gradient (или *ошибка нейрона*)  
(вычисляем для каждого нейрона однократно и сохраняем)

$$\frac{\partial E}{\partial w_{11}^{(2)}} = \frac{\partial E}{\partial o_1} \frac{\partial o_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial w_{11}^{(2)}} = \frac{\partial E}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial w_{11}^{(2)}}$$

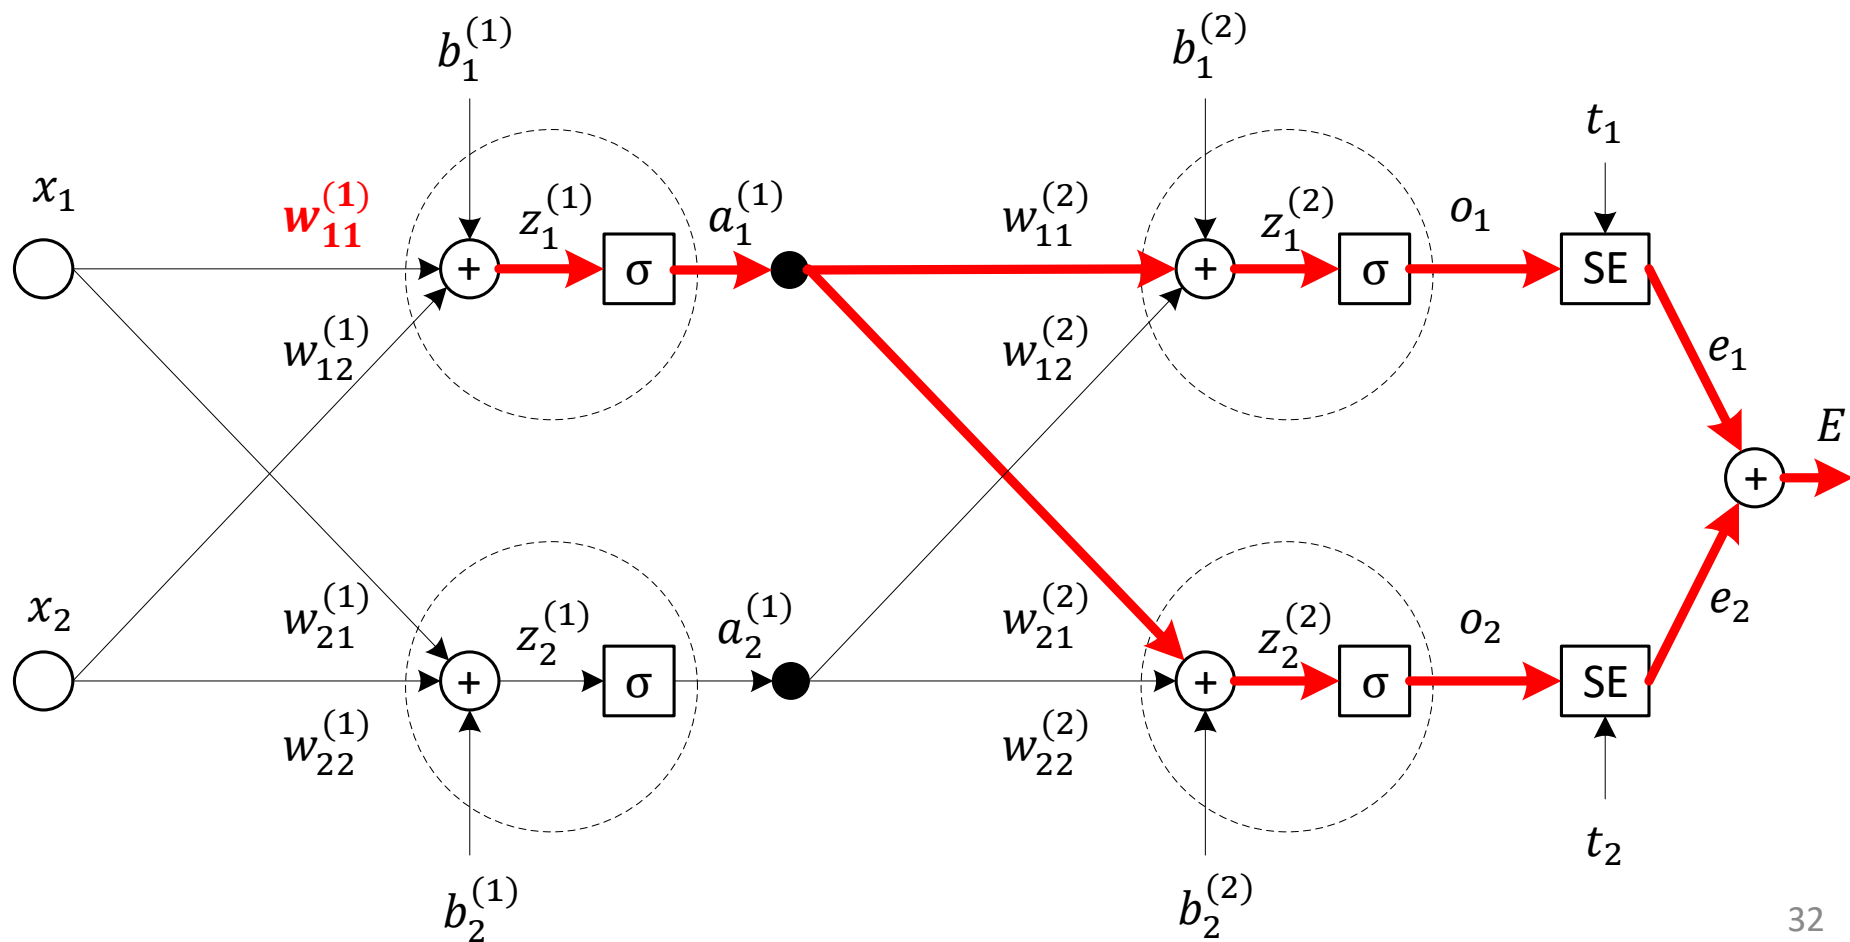


# Градиент скрытого слоя

$$\frac{\partial E}{\partial w_{11}^{(1)}} =$$



$$\frac{\partial E}{\partial w_{11}^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}} \quad - \text{цепное правило, (chain rule)}$$

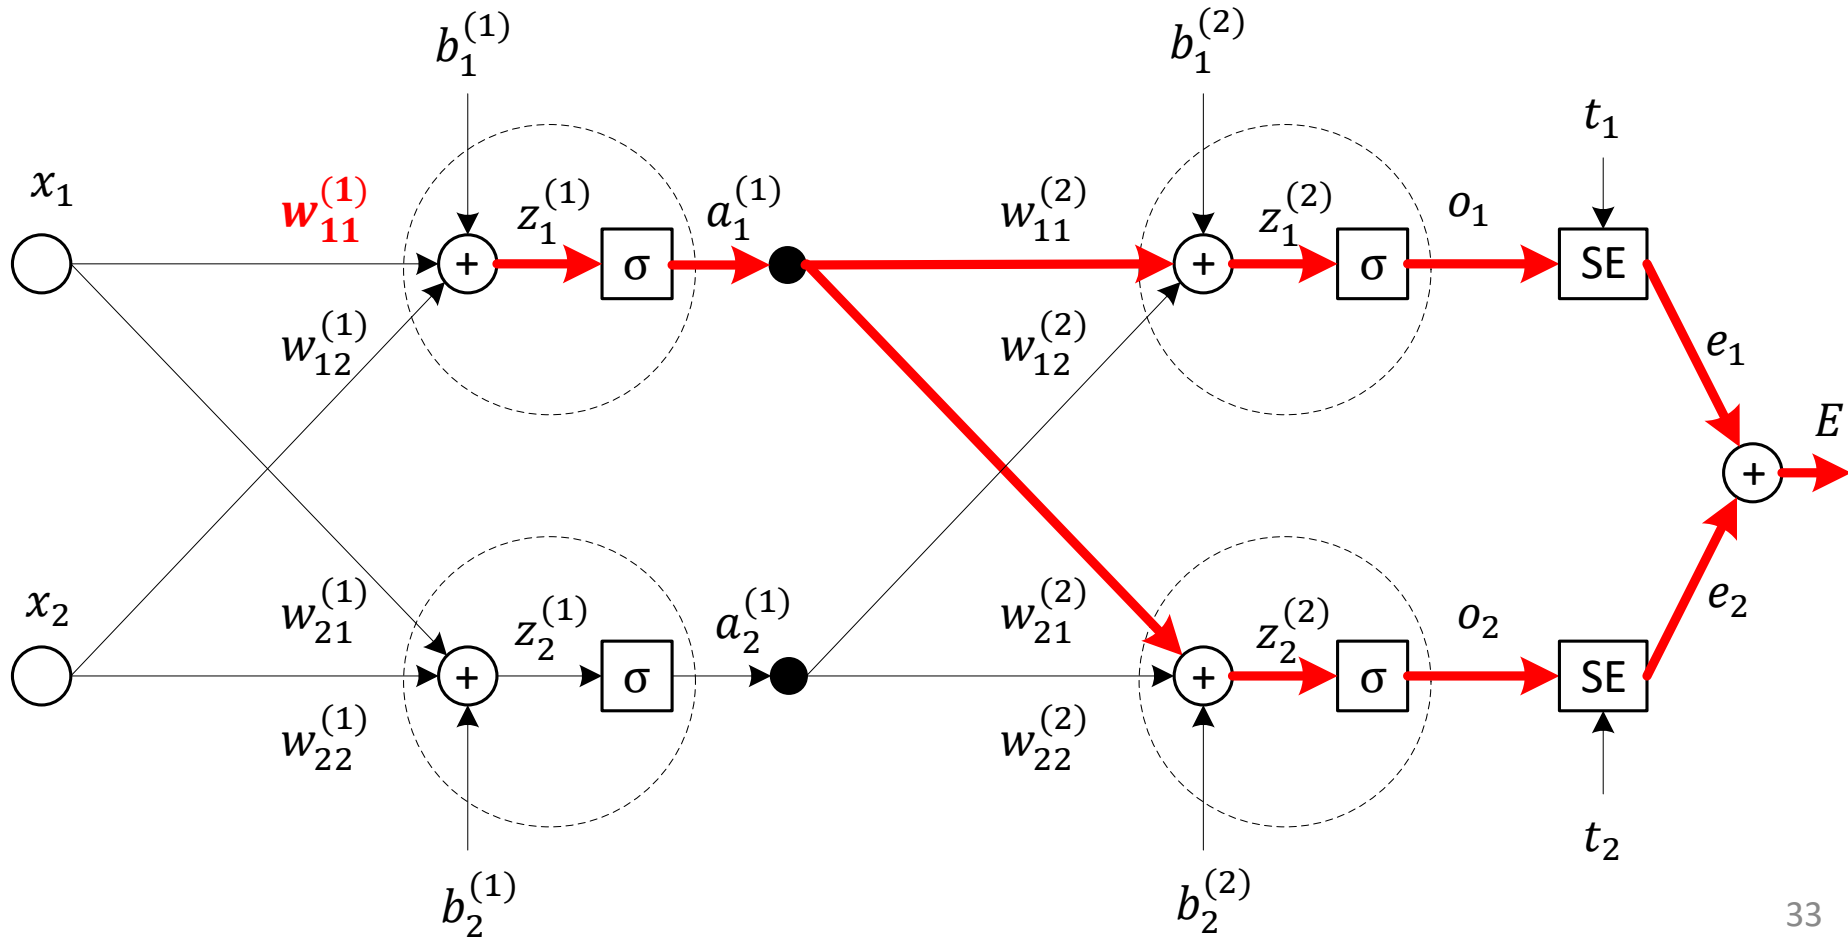




$$\frac{\partial E}{\partial w_{11}^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}}$$

$$E = e_1 + e_2 = \frac{1}{2}(t_1 - o_1)^2 + \frac{1}{2}(t_2 - o_2)^2$$

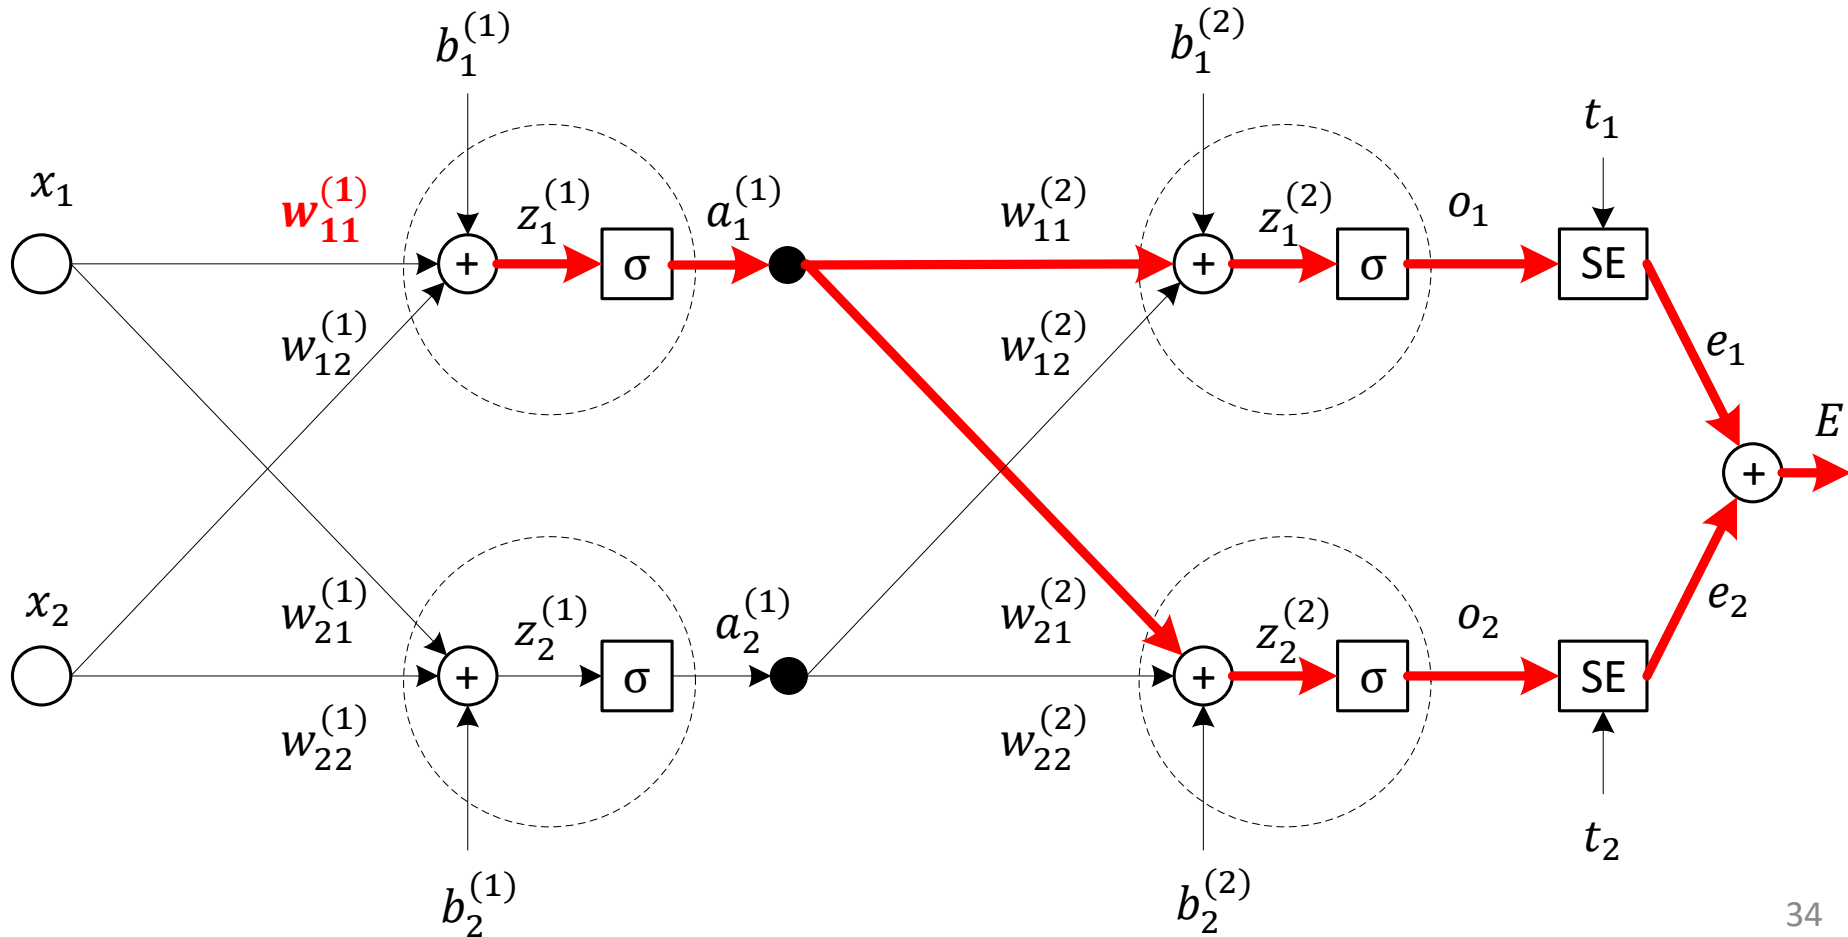
$$\frac{\partial E}{\partial a_1^{(1)}} = \frac{\partial e_1}{\partial a_1^{(1)}} + \frac{\partial e_2}{\partial a_1^{(1)}}$$



$$\frac{\partial E}{\partial w_{11}^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}}$$

$$\frac{\partial E}{\partial a_1^{(1)}} = \frac{\partial e_1}{\partial a_1^{(1)}} + \frac{\partial e_2}{\partial a_1^{(1)}}$$


$$\frac{\partial e_1}{\partial a_1^{(1)}} = \frac{\partial e_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial a_1^{(1)}}$$



$$\frac{\partial E}{\partial w_{11}^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}}$$

$$\frac{\partial E}{\partial a_1^{(1)}} = \frac{\partial e_1}{\partial a_1^{(1)}} + \frac{\partial e_2}{\partial a_1^{(1)}}$$

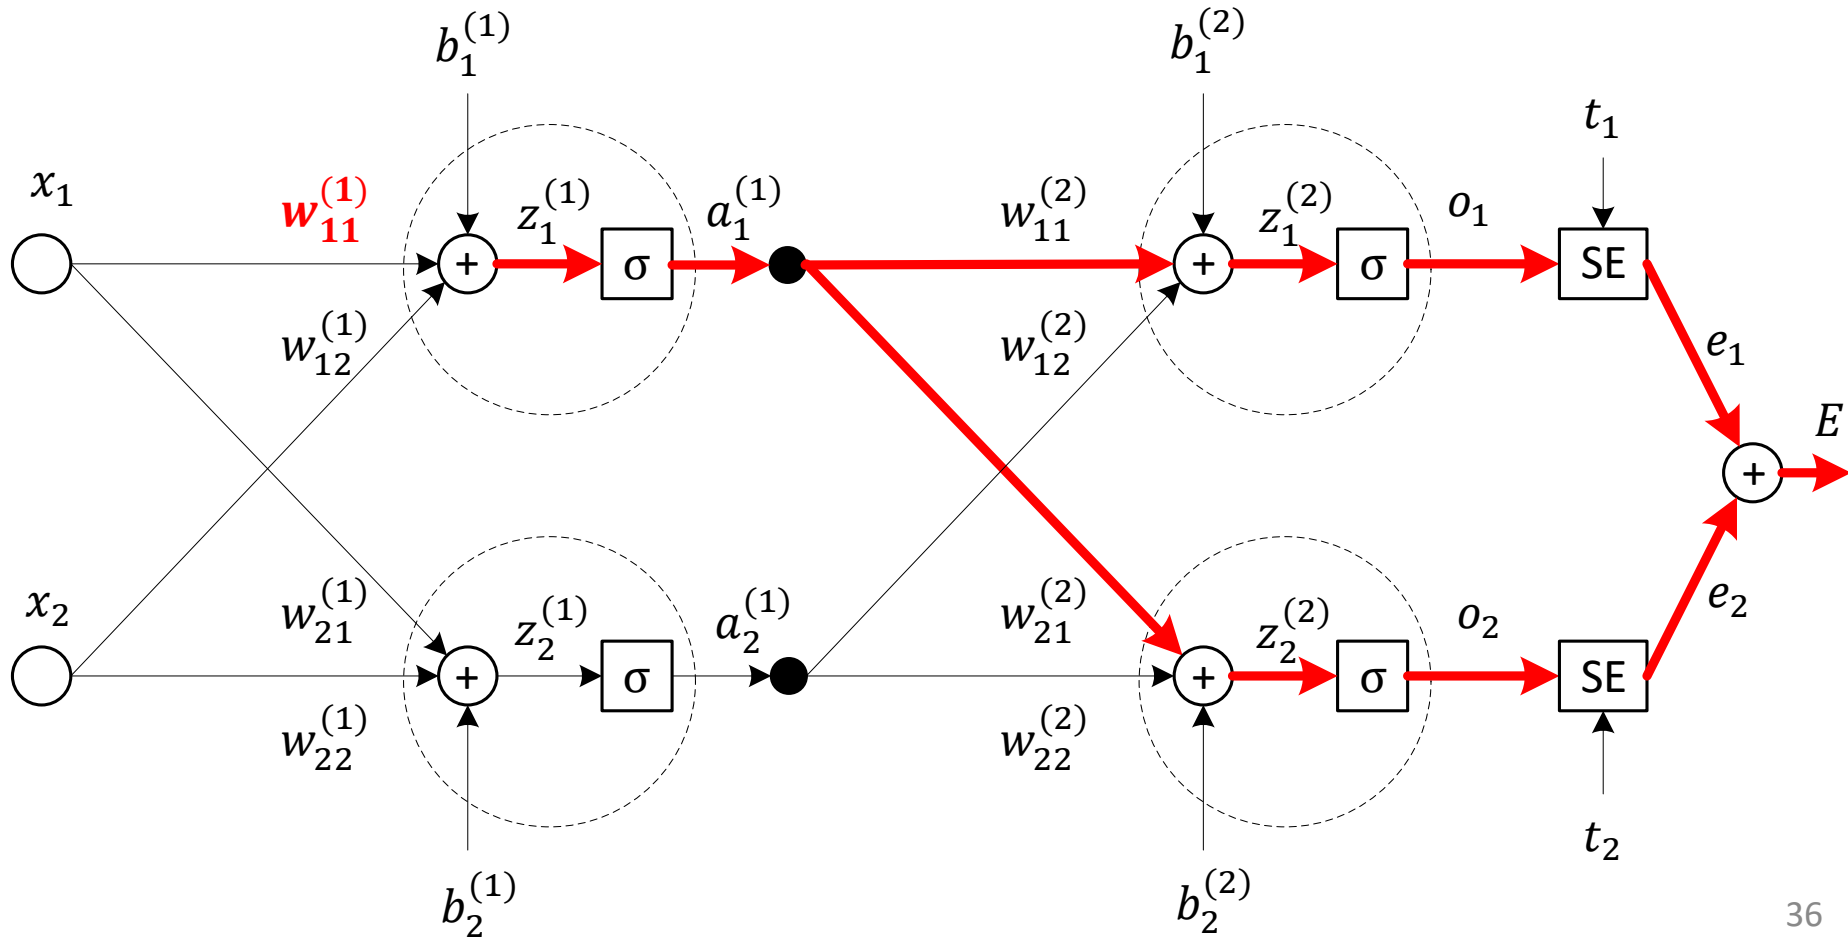
$$\frac{\partial e_1}{\partial a_1^{(1)}} = \frac{\partial e_1}{\partial z_1^{(2)}} \frac{\partial z_1^{(2)}}{\partial a_1^{(1)}} = \frac{\partial E}{\partial z_1^{(2)}} w_{11}^{(2)}$$



$$\frac{\partial E}{\partial w_{11}^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}}$$

$$\frac{\partial E}{\partial a_1^{(1)}} = \frac{\partial e_1}{\partial a_1^{(1)}} + \frac{\partial e_2}{\partial a_1^{(1)}}$$


$$\frac{\partial e_2}{\partial a_1^{(1)}} = \frac{\partial e_2}{\partial z_2^{(2)}} \frac{\partial z_2^{(2)}}{\partial a_1^{(1)}}$$



$$\frac{\partial E}{\partial w_{11}^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}}$$

$$\frac{\partial E}{\partial a_1^{(1)}} = \frac{\partial e_1}{\partial a_1^{(1)}} + \frac{\partial e_2}{\partial a_1^{(1)}}$$

$$\frac{\partial e_2}{\partial a_1^{(1)}} = \frac{\partial e_2}{\partial z_2^{(2)}} \frac{\partial z_2^{(2)}}{\partial a_1^{(1)}} = \frac{\partial E}{\partial z_2^{(2)}} w_{21}^{(2)}$$

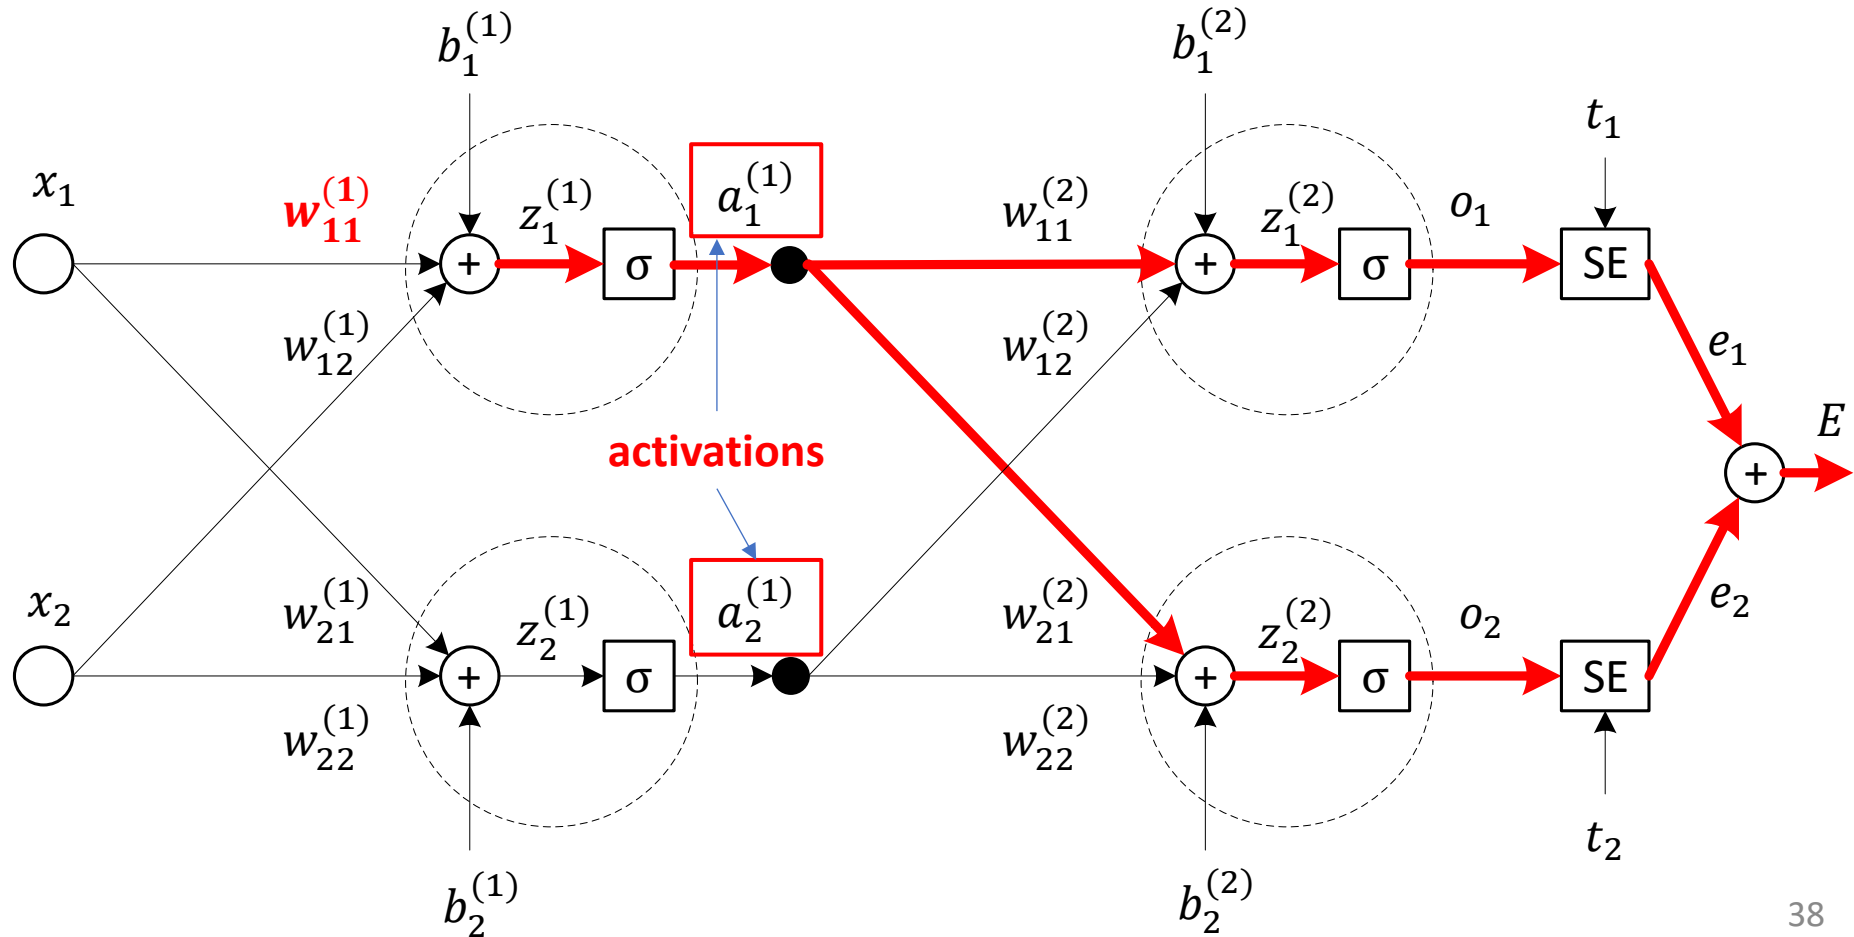


$$\frac{\partial E}{\partial w_{11}^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}}$$

$$a_1^{(1)} = \sigma(z_1^{(1)})$$

Храним активации  
(а  $z_j^{(i)}$  – не храним)

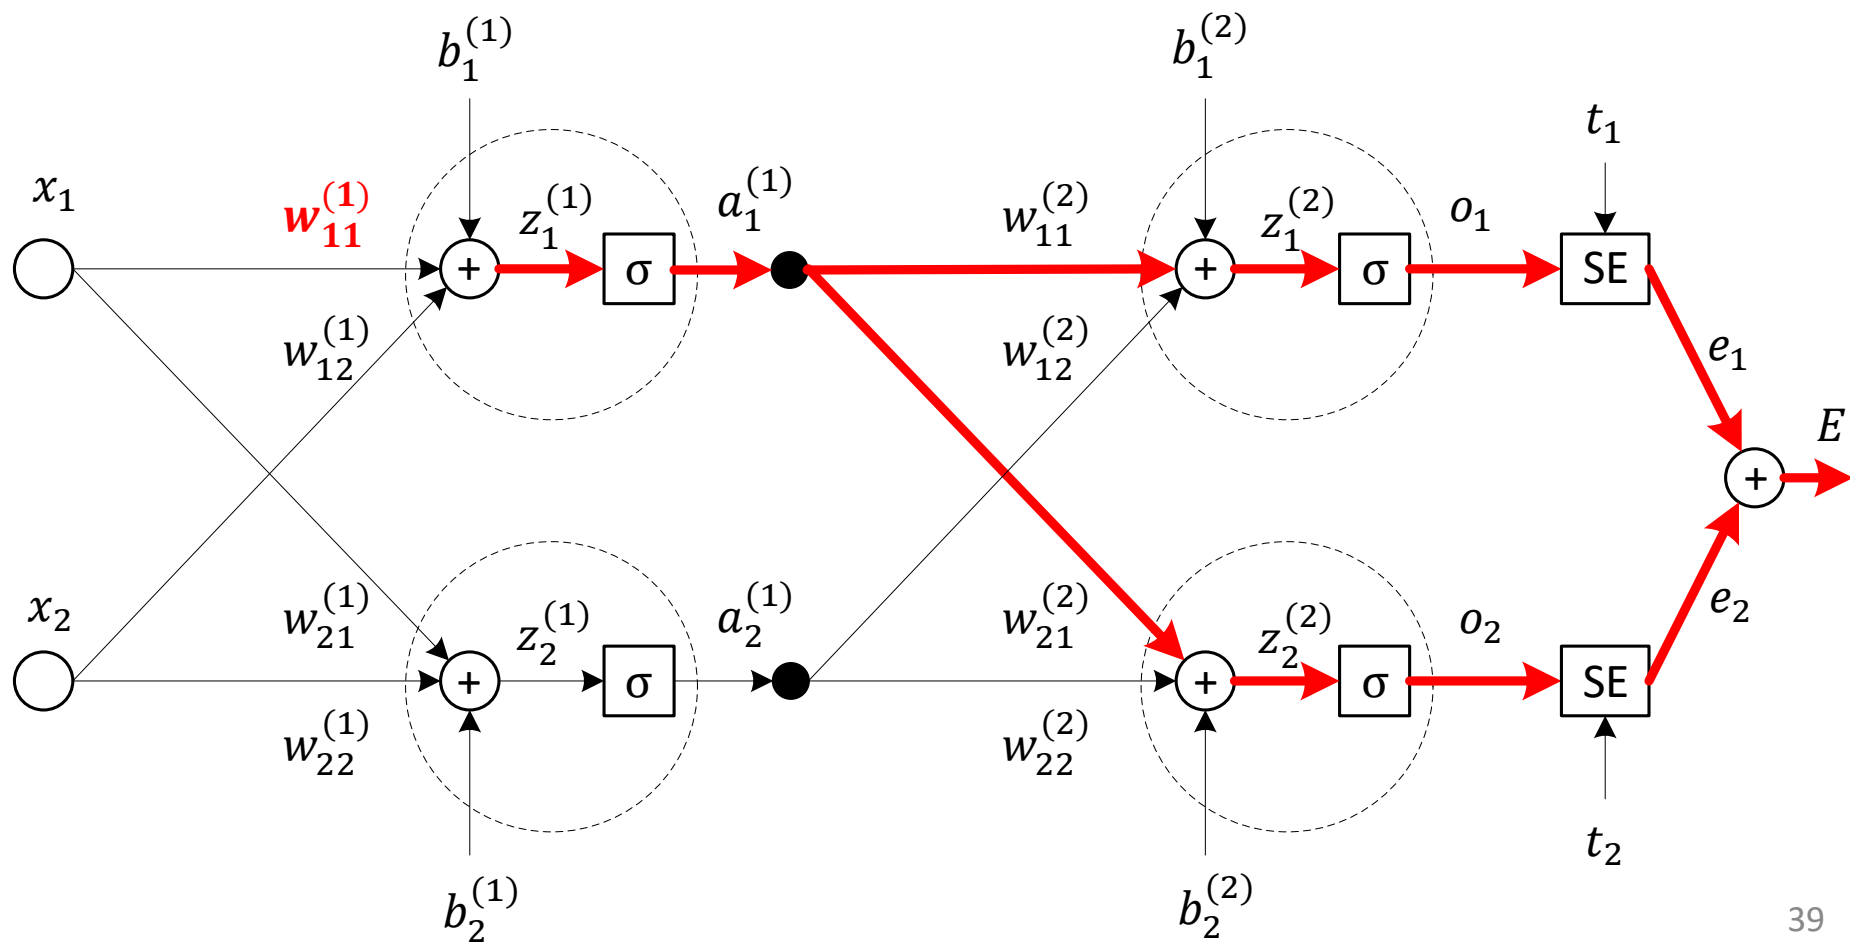
$$\frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} = a_1^{(1)}(1 - a_1^{(1)})$$



$$\frac{\partial E}{\partial w_{11}^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}}$$

$$z_1^{(1)} = w_{11}^{(2)} x_1 + w_{12}^{(2)} x_2 + b_1^{(1)}$$

$$\frac{\partial z_1^{(2)}}{\partial w_{11}^{(2)}} = x_1$$



# Градиент скрытого слоя

$$\frac{\partial E}{\partial w_{11}^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}} = \left( \frac{\partial e_1}{\partial a_1^{(1)}} + \frac{\partial e_2}{\partial a_1^{(1)}} \right) \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}} =$$



# Градиент скрытого слоя

$$\begin{aligned}\frac{\partial E}{\partial w_{11}^{(1)}} &= \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}} = \left( \frac{\partial e_1}{\partial a_1^{(1)}} + \frac{\partial e_2}{\partial a_1^{(1)}} \right) \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}} = \\ &= \left( \frac{\partial E}{\partial z_1^{(2)}} w_{11}^{(2)} + \frac{\partial E}{\partial z_2^{(2)}} w_{21}^{(2)} \right) \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}} =\end{aligned}$$

# Градиент скрытого слоя

$$\begin{aligned}\frac{\partial E}{\partial w_{11}^{(1)}} &= \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}} = \left( \frac{\partial e_1}{\partial a_1^{(1)}} + \frac{\partial e_2}{\partial a_1^{(1)}} \right) \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}} = \\ &= \left( \frac{\partial E}{\partial z_1^{(2)}} w_{11}^{(2)} + \frac{\partial E}{\partial z_2^{(2)}} w_{21}^{(2)} \right) \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}} = \\ &= \left( \frac{\partial E}{\partial z_1^{(2)}} w_{11}^{(2)} + \frac{\partial E}{\partial z_2^{(2)}} w_{21}^{(2)} \right) a_1^{(1)} (1 - a_1^{(1)}) x_1\end{aligned}$$

# Градиент скрытого слоя

$$\frac{\partial E}{\partial w_{11}^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}} = \left( \frac{\partial E}{\partial z_1^{(2)}} w_{11}^{(2)} + \frac{\partial E}{\partial z_2^{(2)}} w_{21}^{(2)} \right) a_1^{(1)} (1 - a_1^{(1)}) x_1$$

$$\frac{\partial E}{\partial w_{12}^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{12}^{(1)}} = \left( \frac{\partial E}{\partial z_1^{(2)}} w_{11}^{(2)} + \frac{\partial E}{\partial z_2^{(2)}} w_{21}^{(2)} \right) a_1^{(1)} (1 - a_1^{(1)}) x_2$$

$$\frac{\partial E}{\partial b_1^{(1)}} = \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial b_1^{(1)}} = \left( \frac{\partial E}{\partial z_1^{(2)}} w_{11}^{(2)} + \frac{\partial E}{\partial z_2^{(2)}} w_{21}^{(2)} \right) a_1^{(1)} (1 - a_1^{(1)})$$

# Градиент скрытого слоя

$$\begin{aligned}
 \frac{\partial E}{\partial w_{11}^{(1)}} &= \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{11}^{(1)}} = \left( \frac{\partial E}{\partial z_1^{(2)}} w_{11}^{(2)} + \frac{\partial E}{\partial z_2^{(2)}} w_{21}^{(2)} \right) a_1^{(1)} (1 - a_1^{(1)}) x_1 \\
 \frac{\partial E}{\partial w_{12}^{(1)}} &= \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial w_{12}^{(1)}} = \left( \frac{\partial E}{\partial z_1^{(2)}} w_{11}^{(2)} + \frac{\partial E}{\partial z_2^{(2)}} w_{21}^{(2)} \right) a_1^{(1)} (1 - a_1^{(1)}) x_2 \\
 \frac{\partial E}{\partial b_1^{(1)}} &= \frac{\partial E}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial b_1^{(1)}} = \left( \frac{\partial E}{\partial z_1^{(2)}} w_{11}^{(2)} + \frac{\partial E}{\partial z_2^{(2)}} w_{21}^{(2)} \right) a_1^{(1)} (1 - a_1^{(1)})
 \end{aligned}$$

$$\delta_1^{(1)} = \frac{\partial E}{\partial z_1^{(1)}}$$

Local gradient (или *ошибка нейрона*)  
 (вычисляем для каждого нейрона однократно и сохраняем)

# Алгоритм обратного распространения ошибки

1. Инициализация весов

2. Цикл по эпохам:

- Цикл по батчам:

- Forward propagation для каждого примера из батча

- Вычисление ошибки по батчу

- Back propagation:

$$\delta_i^{(l)} = \begin{cases} -e_i^{(L)} \sigma_i' \left( z_i^{(L)} \right) = -(t_i - o_i) o_i (1 - o_i) & \text{— для выходного слоя } L \\ \sigma_i' \left( z_i^{(L)} \right) \sum_{k \in \text{Children}(i)} \delta_k^{(l+1)} w_{ki}^{(l+1)} & \text{— для других слоев} \end{cases}$$

# Алгоритм обратного распространения ошибки

- Обновление весов:

$$w_{ij}^{(l)}(n+1) = w_{ij}^{(l)}(n) - \eta \delta_i^{(l)} a_j^{(l-1)},$$

$$b_i^{(l)}(n+1) = b_i^{(l)}(n) - \eta \delta_i^{(l)},$$

где  $n$  – номер итерации,

$a_j^{(l-1)}$  – активация на предыдущем слое; если  $l = 1$ , то  $a_j^0 = x_j$

- Критерии останова:

- $\|\nabla E\| < \varepsilon$  – в точке минимума градиент близок к нулю
- $|E(n+1) - E(n)| < \varepsilon$  – ошибка перестает изменяться

# Алгоритм обратного распространения ошибки

1. Инициализация весов

2. Цикл по эпохам: **for epoch in range(num\_epochs):**

- Цикл по батчам: **for i, (images, labels) in enumerate(train\_loader):**

- Forward propagation для каждого примера из батча

**outputs = model(images)**

- Вычисление ошибки по батчу

**loss = loss\_fn(outputs, labels)**

- Back propagation:

**optimizer.zero\_grad()**

**loss.backward()**

$$\delta_i^{(l)} = \begin{cases} -e_i^{(L)} \sigma_i' \left( z_i^{(L)} \right) = -(t_i - o_i) o_i (1 - o_i) \\ \sigma_i' \left( z_i^{(L)} \right) \sum_{k \in \text{Children}(i)} \delta_k^{(l+1)} w_{ki}^{(l+1)} \end{cases}$$

- Обновление весов:

**optimizer.step()**

$$w_{ij}^{(l)}(n+1) = w_{ij}^{(l)}(n) + \eta \delta_i^{(l)} a_j^{(l-1)},$$

$$b_i^{(l)}(n+1) = b_i^{(l)}(n) + \eta \delta_i^{(l)}$$

# ССЫЛКИ

- 3Blue1Brown – Что на самом деле делает обратное распространение ошибки?
  - <https://www.youtube.com/watch?v=Ilg3gGewQ5U>
  - <https://www.youtube.com/watch?v=tIeHLnjs5U8>
- Matt Mazur – A Step by Step Backpropagation Example
  - <https://mattmazur.com/2015/03/17/a-step-by-step-backpropagation-example>
- Jason Brownlee – How to Code a Neural Network with Backpropagation In Python (from scratch)
  - <https://machinelearningmastery.com/implement-backpropagation-algorithm-scratch-python/>
- Neural Networks and Deep Learning – How the backpropagation algorithm works
  - <http://neuralnetworksanddeeplearning.com/chap2.html>