

# К лекции 5. Модель Prophet

Д. В. Чупраков

13 февраля 2024 г.

## 1 Модель prophet

В 2017 г. специалисты компании Facebook объявили о разработанном ими новом пакете для прогнозирования временных рядов — prophet («пророк»), который позволяет создавать прогнозные модели в (полу-)автоматическом режиме.

Подробное описание реализованной в prophet методологии можно найти в статье [Taylor and Letham \(2017\)](#)<sup>1</sup>.

В основе этой методологии лежит процедура подгонки аддитивных регрессионных моделей (Generalized Additive Models, GAM) следующего вида:

$$y(t) = g(t) + s(t) + h(t) + x(t) + \varepsilon_t,$$

где  $g(t)$  — функция, аппроксимирующая тренд ряда,  $s(t)$  — функции, описывающая сезонные колебания (например, годовые, недельные и т.п.) соответственно,  $h(t)$  — функция, отражающая эффекты праздников и других изолированных, но оказывающих существенное влияние событий,  $x(t)$  — функция, отражающая влияние внешних регрессоров,  $\varepsilon_t$  — нормально распределенные случайные возмущения.

### 1.1 Модель тренда

Тренд в модели Prophet описывается кусочно-логистической функцией

$$g(t) = \frac{C(t)}{1 + e^{-k(t) \cdot (t - m(t))}}$$

где  $C(t)$  — верхний порог (емкость источника) в момент времени  $t$ ,  $k$  — скорость роста,  $m$  — параметр смещения, если временной ряд демонстрирует кумулятивный рост подобный модели роста населения и кусочно-линейной функцией:

$$g(t) = kt + m,$$

если кумулятивного роста не наблюдается.

Изменения вида тренда происходят в моменты времени  $s_1, s_2, \dots, s_S$ .

---

<sup>1</sup>Taylor, S. J., Letham, B. (2017). Forecasting at Scale. The American Statistician, 72(1), 37–45. doi:10.1080/00031305.2017.1380080 URL: <http://lethalletham.com/ForecastingAtScale.pdf>

Введем вектор корректировок скорости  $\delta \in \mathbb{R}^S$ , где  $\delta_j$  — изменение скорости роста временного ряда, наблюдаемое в момент времени  $s_j$ . Тогда скорость изменения тренда в каждый момент времени  $t$  получается из базовой скорости  $k$  прибавлением всех корректировок до этого момента:

$$v_t = k + \sum_{j:t > s_j} \delta_j = k + a(t)^T \delta$$

где вектор  $a(t) \in \{0, 1\}^S$  задан своими компонентами по следующей формуле:

$$\vec{a}_j(t) = \begin{cases} 1, & t \geq s_j \\ 0, & t < s_j \end{cases}$$

Аналогично смещение в точке изменения  $s_j$  легко вычисляется по формуле

$$\gamma_j = \left( s_j - m - \sum_{l < j} \gamma_l \right) \frac{\delta_j}{k + \sum_{l \leq j} \delta_l}$$

Итак, функция тренда на каждом промежутке имеет один из видов:

$$g(t) = \frac{C(t)}{1 + \exp \left( - \left( k + \vec{a}(t)^T \vec{\delta} \right) \left( t - \left( m + \vec{a}(t)^T \vec{\gamma} \right) \right) \right)}$$

$$g(t) = \left( k + \vec{a}(t)^T \vec{\delta} \right) \cdot t + \left( m + \vec{a}(t)^T \vec{\gamma} \right),$$

где вектор  $\vec{\gamma}$  определен покомпонентно равенствами  $\gamma_j = -s_j \delta_j$  чтобы обеспечить непрерывность функции тренда.

Точки изменения  $s_j$  могут быть явно заданы исследователем, на основе знания событий, влияющих на динамику исследуемого процесса или могут быть автоматически выбраны из набора кандидатов.

При автоматическом выборе точек изменения тренда оценивается вектор  $\vec{\delta}$  в предположении, что его компоненты распределены по закону Лапласа:  $\delta_j \sim \text{Laplace}(0, \tau)$ . Параметр  $\tau$  управляет гибкостью модели при изменении ее скорости. если  $\tau$  стремится к 0, то тренд вырождается в не кусочную логистическую или линейную функцию.

Будущие изменения скорости, которые имитируют изменения в прошлом, определяя параметр  $\tau$  методами байесовской статистики: методом нахождения апостериорного максимума (MAP) и путем полного байесовского вывода.

Точки изменения тренда выбираются случайным образом так, чтобы средняя частота точек изменений совпадала с таковой в истории. То есть  $\delta_j \sim \text{Laplace}(0, \tau)$  с вероятностью  $\frac{S}{T}$  и  $\delta_j = 0$  с вероятностью  $1 - \frac{S}{T}$ .

## 1.2 Сезонность

Временные ряды часто имеют многопериодную сезонность. Например, рабочий график обеспечивает недельную сезонность, а климатические факторы — годовую.

Чтобы обеспечить учет сезонностей с разными периодами Функция сезонности представляется в виде отрезка ряда Фурье:

$$s(t) = \sum_{n=1}^N \left( a_n \cos \frac{2\pi nt}{P} + b_n \sin \frac{2\pi nt}{P} \right)$$

где  $P$  — регулярный период, который, как мы ожидаем, будет иметь временной ряд (например,  $P = 365.25$  для годовых данных или  $P = 7$  для недельных данных).

Таким образом функция сезонной компоненты может быть представлена в векторном виде  $s(t) = \vec{X}(t) \cdot \vec{\beta}^T$  где

$$\vec{X}(t) = \left( \cos \frac{2\pi \cdot 1 \cdot t}{P}, \sin \frac{2\pi \cdot 1 \cdot t}{P}, \dots, \cos \frac{2\pi \cdot N \cdot t}{P}, \sin \frac{2\pi \cdot N \cdot t}{P} \right)$$

$$\vec{\beta} = (a_1, b_1, \dots, a_N, b_N)$$

Иными словами, вычисление функции сезонности требует оценки  $2N$  параметров? что делается путем построения матрицы векторов сезонности для каждого значения  $t$  в исторических данных.

Элементы вектора  $\vec{\beta}$  берутся из нормального распределения  $N(0, \sigma^2)$ .

Усечение ряда до  $N$  компонент реализует фильтр высоких частот поэтому числа частот ведет к повышенному риску переобучения, но позволяет моделировать быстро меняющиеся процессы. Эмпирически для годовой и недельной сезонности подходят значения  $N = 10$  и  $N = 3$  соответственно. Выбор этих параметров может быть автоматизирован с помощью информационных критериев качества модели, например AIC.

### 1.3 Праздники

Праздники и события вызывают значительные, в некоторой степени предсказуемые изменения во многих временных рядах бизнеса и часто не следуют периодической схеме (праздники по лунному календарю, фестивали и т. д., презентации новых товаров и т. д.), поэтому их последствия плохо моделируются тригонометрическими функциями. В то же время влияние конкретного праздника на временные ряды часто бывает одинаковым из года в год, поэтому важно учитывать это в прогнозе.

Будем считать, что все праздники независимы. Поэтому, для каждого праздника  $i$  пусть  $D_i$  — набор прошлых и будущих дат для этого праздника. Рассмотрим характеристическую функцию  $\mathbf{1}(t \in D)$  для каждого праздника  $D$  сопоставляющую моменту времени наличие праздника. присваиваем каждому празднику параметр  $\vec{\kappa}_i$ , характеризующий изменение в прогнозе. Это делается аналогично сезонности путем генерации матрицы регрессоров

$$Z(t) = (\mathbf{1}(t \in D_1), \dots, \mathbf{1}(t \in D_L))$$

и найдем  $h(t) = Z(t) \cdot \vec{\kappa}^T$  Как и в случае с сезонностью, используются нормально распределенные значения  $\kappa$  с нулевым математическим ожиданием.

## 2 Интерфейс Prophet

**Установка:** `python -m pip install prophet` или `conda install -c conda-forge prophet`.  
Пакет до версии 1.0 носил название `fbprophet` поэтому в сети много информации именно под такое написание пакета. Ставить же надо пакет `prophet`.

**Структура входного файла:** Формат обучающей выборки имеет два обязательных поля `xs` — временная метка и `y` - значение уровня. Остальные поля являются полями внешних признаков. Также возможно указание емкости источника — столбец `cap`.

**Структура файла праздников:**

**Структура конструктора класса Prophet:**

Модель Prophet подключается стандартно: `from prophet import Prophet` Аргументы конструктора следующие:

- `growth` — тип тренда: `linear`, `logistic` или `flat`
- `yearly_seasonality`, `weekly_seasonality`, `daily_seasonality` — виды сезонностей: принимает логическое значение, число компонент в ряде Фурье или `'auto'`.
- `holidays` — таблица праздников.
- `seasonality_mode` и `holidays_mode` тип сезонности и праздников: `'additive'`, `'multiplicative'`.
- `seasonality_prior_scale`, `holidays_prior_scale` — определяют силу соответствующей компоненты. Большие значения приводят к большему влиянию соответствующей компоненты.
- `changepoints` — список точек изменения тренда
- `n_changepoints` — число точек изменения тренда
- `changepoint_range`: Доля исторических данных, в которой будут искаться точки изменения тренда - число от 0 до 1 по умолчанию — 0.8.
- `changepoint_prior_scale` — Параметр, регулирующий гибкость автоматического выбора точки изменения. С увеличением значения увеличивается число точек изменения тренда.
- `mcmc_samples` — число итераций байесовского вывода. если 0, то используется алгоритм MAP оценки.

Полезное:

```
from prophet.diagnostics import cross_validation, performance_metrics
from prophet.plot import plot_cross_validation_metric
plot_cross_validation_metric(df_cv, metric = 'rmse');
df_cv = cross_validation(m,
horizon = '31 days', period = '16 days', initial = '365 days', parallel = 'processes')
m.add_regressor('regressor_1')
model.add_seasonality(name='weekly_on_winter',
period=7, fourier_order=3, condition_name='зима')
```